

## TD 6 – Optimisation Réseaux de neuronnes

▷ Exercice 1. On s'intéresse ici à la modélisation via un neurone formel.

**Définition 1.** Un neurone formel est une fonction paramétrée par n+1 paramètres  $w_1, \ldots, w_n, b$ :

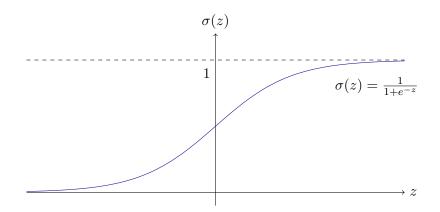
$$g: \mathbb{R}^n \times \mathbb{R}^n \times \mathbb{R} \longrightarrow \mathbb{R}$$
  
 $(x, w, b) \longmapsto g(x, w, b) := \sigma(\sum_{i=1}^n w_i x_i + b)$ 

où  $\sigma$  est une fonction donnée qui s'appelle une fonction d'activation. Chaque paramètre  $w_i$  s'appelle le poids synaptique associé au signal d'entrée  $x_i$ .

On prendra dans la suite, sauf mention contraire, comme fonction  $\sigma$  la fonction sigmoïde :

$$\sigma \colon \mathbb{R} \longrightarrow \mathbb{R}$$

$$z \longmapsto \sigma(z) \coloneqq \frac{1}{1 - e^{-z}}.$$



La figure 1 schématise un neurone formel.

- 1. produit scalaire entre les entrées x et les poids synaptiques  $w: w^T x$ ;
- 2. ajout d'une valeur de référence (biais b) :  $z = w^T x + b$
- 3. application de la fonction d'activation à la valeur obtenue  $z: a = \sigma(z)$

**Définition 2.** On a à notre disposition K points  $x^k \in \mathbb{R}^n$  et  $y^k \in \mathbb{R}$ , on appelle apprentissage du neurone l'estimation par les moindres carrés des paramètres du neurone.

1.1. Écrire le problème aux moindres carrés qui défini l'apprentissage. On donnera en particulier la fonction résidu r en précisant clairement l'espace de départ et l'espace d'arrivée.

OPTIMISATION TD 6

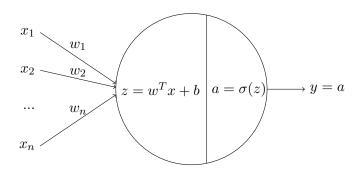


Figure 1 – Représentation schématique d'un neurone.

- **1.2.** Ce problème est-il un problème aux moindres carrés linéaires? Si oui, on donnera la matrice X.
- 1.3. Si on prend comme fonction d'activation  $\sigma$  l'identité, le problème au moindres carrés devient-il linéaire? Si oui, on donnera la matrice X.
- **1.4.** Calculer la dérivée de la fonction à minimiser  $f(\beta)$ .
- ▶ Exercice 2. On considère maintenant le cas d'un réseau à plusieurs couches données par le schéma de la figure 2.

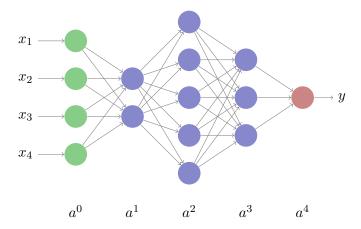


FIGURE 2 – Schéma d'un réseau avec une couche en entré  $(a^0 = x)$ , 3 couches cachés et une couche en sortie.

- **2.1.** On note L le nombre de couches (sans compter la couche d'entrée), donnez :
  - les nombre de neurones  $n_l$  pour  $l=1,\ldots,L$  dans chaque couche et la dimension  $n_0=n$  des données en entrée;
  - Les dimensions des paramètres  $W^l$  et  $b^l$  intervenant dans la couche l.
- **2.2.** On note  $a^l$  la sortie de la couche l ( $a^l$  s'appelle dans la terminologie des réseaux de neurones l'activation de la couche l). Écrire  $a^{l+1}$  en fonction de  $a^l, W^{l+1}, b^{l+1}$  et de  $\sigma$ . En déduire la fonction exprimant y en fonction de x et des paramètres du modèle :  $y(x, \beta)$ .
- **2.3.** On suppose que l'on a comme données K couples  $(x^k, y^k)_{k=1,\dots,K}$ , où  $x^k \in \mathbb{R}^n$  et  $y^k \in \mathbb{R}$ . Écrire dans ce cas le problème aux moindres carrés qui définit l'apprentissage.

OPTIMISATION TD 6

**2.4.** Calculer les dérivées partielles de  $y(x,\beta)$  par rapport à  $\beta^4=(W^4,b^4)$  et par rapport à  $\beta^3$ .

- **2.5.** En déduire les dérivées partielles de la fonction à minimiser par rapport à ces paramètres  $\beta^4$  et  $\beta^3$ .
- **2.6.** Généralisation au cas d'un réseaux à L couches (hors la couche d'entrée) avec un nombre  $n_l$  de neurones pour la couche l (la sortie y étant toujours un élément de  $\mathbb{R}$ ).

## Remarque 1. En pratique :

- la sortie y est dans  $\mathbb{R}^{n_L}$ ;
- On n'utilise pas les moindres carrées, mais une autre fonction coût ;

— ...