

TP4 – Classification par SVM

Le but de ce TP est de tester une autre méthode de classification que celle du TP3, sur les mêmes données. Lancez le script `exercice_0`, qui affiche les caractéristiques de *compacité* et de *contraste* des images de l'ensemble d'apprentissage du TP3, correspondant aux classes « mélanomes » et « fibromes ». Ces données ne sont pas *linéairement séparables*, mais il suffit d'en retirer quelques-unes pour qu'elles le deviennent. Pour ce faire, affectez aux variables `X` et `Y` de ce script, non plus `X_app` et `Y_app`, mais `X_app_filtre` et `Y_app_filtre`.

Exercice 1 : séparateur linéaire (formulation « primale »)

Soit $\mathbf{X}_{\text{app}} = (\mathbf{x}_i)_{i \in \{1, \dots, n\}}$ un ensemble de n points du plan, constitué de deux classes ω_1 et ω_2 linéairement séparables, dont les *étiquettes*, notées y_i , valent -1 ou 1 . L'équation cartésienne d'une droite \mathcal{D} du plan s'écrit :

$$\mathbf{w}^\top \mathbf{x} - c = 0 \quad (1)$$

où le vecteur non nul \mathbf{w} est orthogonal à \mathcal{D} , où \mathbf{x} désigne un point du plan et où c est un paramètre réel. Comme les deux demi-plans limités par \mathcal{D} sont définis par $\mathcal{D}_1 = \{\mathbf{x} \in \mathbb{R}^2, \mathbf{w}^\top \mathbf{x} - c \leq 0\}$ et $\mathcal{D}_2 = \{\mathbf{x} \in \mathbb{R}^2, \mathbf{w}^\top \mathbf{x} - c \geq 0\}$, on peut imposer la contrainte suivante à toute droite \mathcal{D} constituant un *séparateur linéaire* de ω_1 et ω_2 :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) > 0, \quad \forall i \in \{1, \dots, n\} \quad (2)$$

Parmi l'infinité de séparateurs linéaires vérifiant la contrainte (2), le SVM est celui qui maximise le carré de la distance minimale des points $\mathbf{x}_i \in \mathbf{X}_{\text{app}}$ à \mathcal{D} , ce qui s'écrit :

$$\max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \min_{\mathbf{x}_i \in \mathbf{X}_{\text{app}}} \left\{ \frac{(\mathbf{w}^\top \mathbf{x}_i - c)^2}{\|\mathbf{w}\|^2} \right\} \right\} \equiv \max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{\|\mathbf{w}\|^2} \min_{\mathbf{x}_i \in \mathbf{X}_{\text{app}}} \{(\mathbf{w}^\top \mathbf{x}_i - c)^2\} \right\} \quad (3)$$

Or, l'équation cartésienne (1) de \mathcal{D} est inchangée si \mathbf{w} et c sont multipliés par un même coefficient strictement positif. On peut donc choisir ce coefficient de telle sorte que, pour les points \mathbf{x}_i les plus proches de \mathcal{D} , qui sont appelés *vecteurs de support*, on ait exactement $y_i (\mathbf{w}^\top \mathbf{x}_i - c) = 1$. Dès lors, la contrainte (2) peut être réécrite :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 \geq 0, \quad \forall i \in \{1, \dots, n\} \quad (4)$$

D'autre part, comme la valeur minimale de $(\mathbf{w}^\top \mathbf{x}_i - c)^2$ vaut alors 1, le problème (3) se simplifie en :

$$\max_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{\|\mathbf{w}\|^2} \right\} \equiv \min_{\mathbf{w} \in \mathbb{R}^2, c \in \mathbb{R}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 \right\} \quad (5)$$

qui constitue un problème de *minimisation quadratique*, sous les contraintes linéaires (4) de type inégalités.

Écrivez la fonction `SVM_1`, appelée par le script `exercice_1`, permettant de résoudre le problème (4) + (5). Les problèmes de minimisation quadratique sous contraintes (de types égalités et/ou inégalités) peuvent être résolus de manière efficace par la fonction `quadprog` de Matlab (`help quadprog`). Les inconnues du problème doivent être concaténées en un vecteur $\tilde{\mathbf{w}} = [\mathbf{w}^\top, c]^\top \in \mathbb{R}^3$, et le problème reformulé sous forme « canonique » :

$$\begin{cases} \min_{\tilde{\mathbf{w}} \in \mathbb{R}^3} \left\{ \frac{1}{2} \tilde{\mathbf{w}}^\top \mathbf{H} \tilde{\mathbf{w}} \right\} \\ \text{s.c.} \quad \mathbf{A} \tilde{\mathbf{w}} \leq \mathbf{b} \end{cases} \quad (6)$$

Conseils de programmation :

- Attention au sens de l'inégalité dans la contrainte de (6), qui diffère du sens de l'inégalité dans (4).
- La fonction `SVM_1` doit retourner les estimations de \mathbf{w} et de c , ainsi que les vecteurs de support `X_VS`, qui sont les points $\mathbf{x}_i \in \mathbf{X}_{\text{app}}$ pour lesquels (4) est une égalité. Néanmoins, plutôt que l'opérateur `==`, il convient d'utiliser un seuil très faible, par exemple 10^{-6} , sur l'écart entre les deux membres de (4).
- Le dernier paramètre de sortie de `SVM_1` est le code de retour de `quadprog` (« `exitflag` »), qui vaut 1 lorsque la résolution converge. Vérifiez que cela n'est pas le cas avec les données `X_app` et `Y_app`.

Exercice 2 : séparateur linéaire (formulation « duale »)

Une autre façon de résoudre le problème (4) + (5) consiste à introduire le *lagrangien* associé, qui dépend non seulement de \mathbf{w} et de c , mais également de n *multiplicateurs de Lagrange*, notés $\alpha_i \in \mathbb{R}$, correspondant aux n contraintes linéaires (4) :

$$\begin{aligned}\mathcal{L}(\mathbf{w}, c, \alpha_1, \dots, \alpha_n) &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i [y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1] \\ &= \frac{1}{2} \mathbf{w}^\top \left\{ \mathbf{w} - 2 \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \right\} + c \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i\end{aligned}\quad (7)$$

Comme les contraintes (4) sont de type ≥ 0 , les multiplicateurs α_i doivent vérifier la contrainte suivante :

$$\alpha_i \geq 0, \quad \forall i \in \{1, \dots, n\} \quad (8)$$

De plus, les seuls indices i pour lesquels $\alpha_i > 0$ sont ceux des vecteurs de support, là où $y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0$. Les conditions d'optimalité du premier ordre de \mathcal{L} , relativement à \mathbf{w} et à c , s'écrivent, respectivement :

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \quad (9)$$

$$\sum_{i=1}^n \alpha_i y_i = 0 \quad (10)$$

La *fonction duale* du lagrangien \mathcal{L} , qui ne dépend que des α_i , s'obtient en réinjectant (9) et (10) dans (7) :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}_j y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (11)$$

Cette fonction étant quadratique mais concave, il faut rechercher son maximum en résolvant un nouveau problème d'optimisation quadratique sous contraintes : contraintes (10) de type égalités + contraintes (8) de type inégalités. En introduisant le vecteur $\boldsymbol{\alpha} = [\alpha_1, \dots, \alpha_n]^\top$, la forme canonique de ce problème s'écrit :

$$\begin{cases} \max_{\boldsymbol{\alpha} \in \mathbb{R}^n} \left\{ -\frac{1}{2} \boldsymbol{\alpha}^\top \mathbf{H} \boldsymbol{\alpha} + \mathbf{f}^\top \boldsymbol{\alpha} \right\} \\ \text{s.c.} \begin{cases} \mathbf{A}_{\text{eq}} \boldsymbol{\alpha} = 0 \\ \boldsymbol{\alpha} \geq \mathbf{0}_{\mathbb{R}^n} \end{cases} \end{cases} \quad (12)$$

Écrivez la fonction `SVM_2`, appelée par le script `exercice_2`, permettant de résoudre le problème (12) par un appel à la fonction `quadprog`.

Conseils de programmation :

- Attention au fait que (12) est un problème de *maximisation*, et non de minimisation.
- Une fois trouvés les multiplicateurs de Lagrange, les vecteurs de support `X_VS` sont faciles à identifier, puisque ce sont les points \mathbf{x}_i dont l'indice i est tel que $\alpha_i > 0$ (utilisez à nouveau un seuil pour ce test).
- Le vecteur \mathbf{w} se déduit de (9), où la somme peut être restreinte aux indices des vecteurs de support.
- Enfin, pour calculer c , il suffit par exemple d'identifier un vecteur de support. En effet, pour un vecteur de support \mathbf{x}_i d'étiquette y_i , nous savons que :

$$y_i (\mathbf{w}^\top \mathbf{x}_i - c) - 1 = 0 \quad (13)$$

En guise de validation de ces deux premiers exercices, vérifiez que `exercice_1` et `exercice_2` affichent le même séparateur linéaire, et que les valeurs obtenues pour \mathbf{w} et c sont les mêmes avec ces deux scripts.

Exercice 3 : données non linéairement séparables

Il est rare que des données non filtrées soient linéairement séparables. Pour pallier ce problème, on peut appliquer aux points \mathbf{x}_i une transformation non linéaire, notée ϕ , de \mathbb{R}^2 dans un espace \mathcal{E} de plus grande dimension. Dans cet espace, on cherche un *hyperplan* séparateur, ayant pour équation cartésienne :

$$\mathbf{w}^\top \phi(\mathbf{x}) - c = 0 \quad (14)$$

où $\mathbf{w} \in \mathcal{E}$ et $c \in \mathbb{R}$, devant vérifier les contraintes suivantes :

$$y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) - c) > 0, \quad \forall i \in \{1, \dots, n\} \quad (15)$$

À ce stade du raisonnement, il est important de remarquer que (14) est une réécriture de (1), dans laquelle \mathbf{x} est remplacé par $\phi(\mathbf{x})$, et (15) une réécriture de (2), dans laquelle \mathbf{x}_i est remplacé par $\phi(\mathbf{x}_i)$. Or, dans la suite du raisonnement, la formulation duale présente un avantage important sur la formulation primale. En effet, l'extension du problème (6) nécessite de changer d'espace de recherche, puisque l'inconnue \mathbf{w} doit être recherchée, dorénavant, dans \mathcal{E} , contrairement à l'inconnue du problème (12), qui est encore $\alpha \in \mathbb{R}^n$. Par ailleurs, l'extension de la fonction duale (11) s'écrit :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (16)$$

qui fait bien intervenir deux vecteurs de \mathcal{E} , mais **seulement par le biais de leur produit scalaire** $\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$. Le « coup du noyau » (*kernel trick*), qui n'est pas une spécificité des SVM, consiste à remplacer ce produit scalaire par une fonction K , appelée *fonction noyau*, ce qui permet de réécrire (16) sous la forme suivante :

$$\bar{\mathcal{L}}(\alpha_1, \dots, \alpha_n) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_j) y_j \alpha_j + \sum_{i=1}^n \alpha_i \quad (17)$$

Le noyau la plus souvent utilisé est le *noyau gaussien* :

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left\{ -\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2} \right\} \quad (18)$$

où le paramètre σ représente un écart-type (vous pourrez tester plusieurs valeurs de ce paramètre).

Écrivez la fonction `SVM_3`, appelée par le script `exercice_3`, permettant de rechercher le maximum de la fonction $\bar{\mathcal{L}}$, définie par (17) et (18), sous les mêmes contraintes que celles du problème (12).

Ajoutez, à la fin du script `exercice_3`, le calcul du pourcentage de bonnes classifications des données de test (non linéairement séparables) et jouez sur la valeur du paramètre σ pour maximiser ce pourcentage.

Conseils de programmation :

- Commencez par calculer la *matrice de Gram*, dont l'élément courant $G(i, j)$ est égal à $K(\mathbf{x}_i, \mathbf{x}_j)$.
- Comme la fonction ϕ n'est pas explicitement connue, \mathbf{w} ne peut pas être calculé explicitement. D'ailleurs, il ne fait pas partie des paramètres de sortie de la fonction `SVM_3`.
- En revanche, c peut être calculé en combinant (13) et (9). Si \mathbf{x}_i est un vecteur de support d'étiquette y_i :

$$y_i \left\{ \sum_{j=1}^n \alpha_j y_j \mathbf{x}_j^\top \mathbf{x}_i - c \right\} - 1 = 0 \quad (19)$$

ce qui donne, en utilisant à nouveau le noyau K pour remplacer les produits scalaires :

$$c = \sum_{j=1}^n \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}_i) - y_i \quad (20)$$

où la somme peut être restreinte aux indices j des vecteurs de support.