

# Méthodes itératives

2022–2023

On cherche une suite  $x^{(p)}$  de  $\mathbb{R}^n$  convergeant vers la solution  $x^*$  de  $A \cdot x = b$

$$\forall x^{(0)} \in \mathbb{R}^n \quad x^{(p+1)} = H(x^{(p)})$$

- ▶ La matrice  $A$  n'est jamais modifiée
- ▶ Problème du suivi de la convergence et du choix du test d'arrêt
- ▶ La solution obtenue n'est pas exacte
- ▶ La matrice doit vérifier des conditions de convergence
- ▶ La vitesse de convergence dépend de la valeur des coefficients de la matrice

## Algorithmes itératifs de relaxation

Algorithmes associés à une décomposition de  $A$  sous la forme  $M - N$  :  
Gauss-Seidel, Jacobi, SOR

## Méthodes de gradient

Plus grande pente, directions conjuguées, gradient conjugué

# Première partie I

## Méthodes itératives de relaxation

## Algorithme itératif de relaxation associé à une décomposition de $A$ sous une forme $M - N$

Soit  $A = M - N$  avec  $M$  inversible

$$\begin{aligned} A \cdot x^* &= b \iff (M - N) \cdot x^* = b \\ &\iff M \cdot x^* = N \cdot x^* + b \\ &\iff x^* = M^{-1} \cdot N \cdot x^* + M^{-1} \cdot b \end{aligned}$$

Algorithme itératif de relaxation associé :

$$\begin{cases} x^{(0)} \in \mathbb{R}^n \\ x^{(p+1)} = M^{-1} \cdot N \cdot x^{(p)} + M^{-1} \cdot b \\ \quad = M^{-1} \cdot (M - A) \cdot x^{(p)} + M^{-1} \cdot b \\ \quad = x^{(p)} + M^{-1} \cdot r^{(p)} \end{cases}$$

avec  $r^{(p)} = b - A \cdot x^{(p)}$  le vecteur résidu

Coût d'une itération (en dehors du calcul du résidu) : résolution d'un système de matrice  $M$

Soit la décomposition de  $A = D - E - F$  avec :

$$D = \begin{pmatrix} a_{11} & 0 & \dots & 0 \\ 0 & \ddots & & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & a_{nn} \end{pmatrix} \quad E = \begin{pmatrix} 0 & \dots & \dots & 0 \\ -a_{21} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ -a_{n1} & \dots & -a_{nn-1} & 0 \end{pmatrix}$$
$$F = \begin{pmatrix} 0 & -a_{12} & \dots & -a_{1n} \\ \vdots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & -a_{n-1n} \\ 0 & \dots & \dots & 0 \end{pmatrix}$$

## Deux variantes

Algorithme de Jacobi :  $M = D$  et  $N = E + F$

L'itération  $p$  consiste à résoudre l'équation :

$$D \cdot x^{(p+1)} - (E + F) \cdot x^{(p)} = b$$

C.N. d'application :  $D$  inversible  $i = 1, \dots, n$   $a_{ii} \neq 0$

Algorithme de Gauss-Seidel :  $M = D - E$  et  $N = F$

L'itération  $p$  consiste à résoudre l'équation :

$$(D - E) \cdot x^{(p+1)} - F \cdot x^{(p)} = b$$

C.N. d'application :  $(D - E)$  inversible  $\iff i = 1, \dots, n$   $a_{ii} \neq 0$

Mise en œuvre du test d'arrêt (à la fin de chaque itération) Choix d'une norme vectorielle  $\|\cdot\|$ , d'une précision  $\varepsilon$  puis d'un test d'arrêt :

- ▶  $\|x^{(p+1)} - x^{(p)}\| < \varepsilon$  : simple mais numériquement dangereux (risque d'arrêt prématuré loin de la solution).
- ▶  $\|b - A \cdot x^{(p+1)}\| / \|b\| < \varepsilon$  : numériquement plus sûr.

La mise en œuvre de ce test d'arrêt n'entraîne pas de calculs supplémentaires

Pour Jacobi : 
$$x^{(p+1)} = D^{-1} \cdot [b - A \cdot x^{(p)}] + x^{(p)}$$

Pour Gauss-Seidel : 
$$x^{(p+1)} = (D - E)^{-1} \cdot [b - A \cdot x^{(p)}] + x^{(p)}$$



# Convergence d'un algorithme issu d'une décomposition de $A = M - N$

Soit  $x^{(p)} = x^* + \varepsilon^{(p)}$

$$\left. \begin{array}{l} x^{(p+1)} = M^{-1} \cdot N \cdot x^{(p)} + M^{-1} \cdot b \\ x^* = M^{-1} \cdot N \cdot x^* + M^{-1} \cdot b \end{array} \right\} \Rightarrow \varepsilon^{(p+1)} = M^{-1} \cdot N \cdot \varepsilon^{(p)}$$
$$\Rightarrow \varepsilon^{(p)} = (M^{-1} \cdot N)^p \cdot \varepsilon^{(0)}$$

$$\text{Convergence} \iff \forall x^{(0)} \in \mathbb{R}^n \quad \lim_{p \rightarrow +\infty} x^{(p)} = x^*$$

$$\iff \forall \varepsilon^{(0)} \in \mathbb{R}^n \quad \lim_{p \rightarrow +\infty} \varepsilon^{(p)} = 0$$

$$\iff \forall \varepsilon^{(0)} \in \mathbb{R}^n \quad \lim_{p \rightarrow +\infty} (M^{-1} \cdot N)^p \cdot \varepsilon^{(0)} = 0$$

$$\iff \lim_{p \rightarrow +\infty} (M^{-1} \cdot N)^p = 0$$

$$\iff \rho(M^{-1} \cdot N) < 1 \quad (\text{propriété admise})$$

## CNS de convergence (admise)

$$\lim_{p \rightarrow +\infty} (M^{-1} \cdot N)^p = 0 \iff \rho(M^{-1} \cdot N) < 1$$

$\rho$  désignant le **rayon spectral** d'une matrice : soient  $\lambda_i \in \mathbb{C}, i = 1, \dots, n$  les valeurs propres d'une matrice  $A$  :

$$\rho(A) = \max_{i=1, \dots, n} |\lambda_i|$$

Autre version de la CNS de convergence :

$$\forall \lambda \in \mathbb{C} \text{ valeur propre de } M^{-1} \cdot N : |\lambda| < 1$$

Première possibilité pour vérifier la convergence : utiliser la CNS

Jacobi :  $\rho(D^{-1} \cdot (E + F)) < 1$

Gauss-Seidel :  $\rho((D - E)^{-1} \cdot F) < 1$

## Exercice 1

Soit le système  $A \cdot x = b$  avec  $A \in \mathcal{M}_n(\mathbb{R})$  inversible.

On considère une décomposition de  $A$  sous la forme  $M - N$ .

On supposera (pour simplifier) que toutes les valeurs propres de la matrice  $M^{-1} \cdot N$  sont réelles et que tous les vecteurs propres associés appartiennent à  $\mathbb{R}^n$ .

Montrer la propriété suivante (réciproque de la propriété admise en cours) :

La méthode itérative de relaxation associée à la décomposition de  $A$  converge vers  $x$  quelque soit le vecteur initial  $\implies \rho(M^{-1} \cdot N) < 1$

## CS de convergence

Deuxième possibilité pour vérifier la convergence : utiliser des CS spécifiques (déduites de la CNS)

$A$  à diagonale dominante :  $i = 1, \dots, n$   
(stricte)  $|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|$   
 $>$

Théorème 1 : Si  $A$  est à diagonale dominante stricte, alors les algorithmes de **Jacobi** et de **Gauss-Seidel** convergent quelque soit le vecteur de départ.

Théorème 2 : Si  $A$  est à diagonale dominante et si :

$$\exists k \in \{1, \dots, n\} \quad |a_{kk}| > \sum_{j=1, j \neq k}^n |a_{kj}|$$

alors l'algorithme de **Gauss-Seidel** converge quelque soit le vecteur de départ.

Théorème 3 : Si  $A$  est symétrique définie positive, alors l'algorithme de **Gauss-Seidel** converge quelque soit le vecteur de départ.

# Méthode SOR (successive over-relaxation)

Technique d'accélération de Gauss-Seidel

$$x_i^{(p+1)} = \omega(\text{Gauss-Seidel}) + (1 - \omega)x_i^{(p)}$$

$$x_i^{(p+1)} = \frac{\omega}{a_{ii}} \left( b_i - \sum_{j>i} a_{ij}x_j^{(p)} - \sum_{j<i} a_{ij}x_j^{(p+1)} \right) + (1 - \omega)x_i^{(p)}$$

C'est un algorithme itératif de relaxation issu d'une décomposition de  $A$  sous la forme  $M_\omega - N_\omega$  avec  $M_\omega = \frac{D}{\omega} - E$  et  $N_\omega = \left(\frac{1}{\omega} - 1\right) D + F$

Conditions sur  $\omega$  pour assurer la convergence ?

Quelques résultats pour des cas particuliers :

- $A$  symétrique définie positive et tridiagonale par blocs, un seul paramètre optimal  $\omega$  :  $\omega = \frac{2}{1 + \sqrt{1 - \rho(D^{-1} \cdot (E+F))^2}}$

## Deuxième partie II

### Méthodes de gradient

Rappel : si  $F : \mathbb{R}^n \rightarrow \mathbb{R}$  et  $x \in \mathbb{R}^n$ ,  $\text{grad}(F)(x) = \begin{pmatrix} \frac{\partial F}{\partial x_1}(x) \\ \vdots \\ \frac{\partial F}{\partial x_n}(x) \end{pmatrix}$

## Propriété 1

$$F : \mathbb{R}^n \rightarrow \mathbb{R}$$


$$x \mapsto F(x) = \frac{1}{2}x^T \cdot A \cdot x - x^T \cdot b$$

Si  $A$  symétrique,  $A \cdot x - b = \text{grad}(F)(x)$  ou  $b - A \cdot x = -\text{grad}(F)(x)$

## Propriété 2

Si  $A$  symétrique définie positive (supposé vrai pour toute méthode de gradient) :  $A \cdot x^* = b \iff \forall x' \neq x^* \quad F(x') > F(x^*)$

# Interprétation de la "steepest descent" en 2D





# Méthode de la Steepest Descent

$A$  symétrique définie positive,  $x^{(0)} \in \mathbb{R}^n$  quelconque

Au cours de l'itération  $p$ ,  $x^{(p+1)}$  se déduit de  $x^{(p)}$  par :

$$x^{(p+1)} = x^{(p)} + \lambda_p r^{(p)}$$

- ▶  $r^{(p)}$  : direction de descente (vecteur)
- ▶  $\lambda_p$  : progression dans la direction de descente (scalaire)

Choix des paramètres de la descente :

- ▶ Direction : suivant la plus grande pente i.e. direction opposée au gradient en  $x^{(p)}$  :  $r^{(p)} = -\text{grad}(F)(x^{(p)}) = b - A \cdot x^{(p)}$
- ▶ Progression : recherche du point "le plus bas" dans la direction  $r^{(p)}$  obtenu en minimisant :

$$f(\lambda) = F(x^{(p)} + \lambda r^{(p)}) - F(x^{(p)}) = \frac{1}{2} \lambda^2 (r^{(p)})^T \cdot A \cdot r^{(p)} - \lambda (r^{(p)})^T \cdot r^{(p)}$$

Le minimum de cette fonction de  $\lambda_p$  est atteint en  $\lambda_p = \frac{(r^{(p)})^T \cdot r^{(p)}}{(r^{(p)})^T \cdot A \cdot r^{(p)}}$

# Algorithme

D'où l'algorithme :

$$x^{(0)} = \dots$$

$$r^{(0)} = b - A \cdot x^{(0)}$$

$$p = 1$$

Tant que  $\frac{\|r^{(p-1)}\|}{\|b\|} > \varepsilon$  faire

$$\lambda_{p-1} = \frac{(r^{(p-1)})^T \cdot r^{(p-1)}}{(r^{(p-1)})^T \cdot A \cdot r^{(p-1)}}$$

$$x^{(p)} = x^{(p-1)} + \lambda_{p-1} r^{(p-1)}$$

$$r^{(p)} = b - A \cdot x^{(p)}$$

$$p = p + 1$$

Coût d'une itération : 2 produits matrice-vecteur mais

$$r^{(p)} = b - A \cdot x^{(p)} = b - A \cdot x^{(p-1)} - \lambda_{p-1} A \cdot r^{(p-1)}$$

$$r^{(p)} = r^{(p-1)} - \lambda_{p-1} A \cdot r^{(p-1)}$$

# Propriétés de la Steepest Descent

- ▶ Deux directions de descente successives  $r^{(p+1)}$  et  $r^{(p)}$  sont orthogonales.
- ▶ Soit  $u$  vecteur propre de  $A$ . Si  $x^{(0)}$  vérifie :  
 $\exists \beta \in \mathbb{R}, \beta \neq 0$  t.q.  $x^* - x^{(0)} = \beta u$ , la SD atteint la solution exacte en une itération.
- ▶ Si toutes les valeurs propres de la matrice  $A$  sont égales (une seule valeur propre), alors,  $\forall x^{(0)}$ , la SD atteint la solution exacte en une itération.

# Propriétés de la Steepest Descent

- Soit  $u$  vecteur propre de  $A$ . Si  $x^{(0)}$  vérifie :  
 $\exists \beta \in \mathbb{R}, \beta \neq 0$  t.q.  $x^* - x^{(0)} = \beta u = \varepsilon^{(0)}$ , la SD atteint la solution exacte en une itération.




Figure 14: Steepest Descent converges to the exact solution on the first iteration if the error term is an eigenvector.

# Propriétés de la Steepest Descent

- Si toutes les valeurs propres de la matrice  $A$  sont égales (une seule valeur propre), alors,  $\forall x^{(0)}$ , la SD atteint la solution exacte en une itération.





Figure 15: Steepest Descent converges to the exact solution on the first iteration if the eigenvalues are all equal.

## cas défavorable de la “steepest descent” en 2D


Jonathan Richard Shewchuk



Référence : *An Introduction to the Conjugate Gradient Method without the Agonizing Pain*, **Jonathan Richard Shewchuk**

Idée : ne considérer une direction qu'une fois

Jonathan Richard Shewchuk



Problème : pour savoir où s'arrêter dans une direction, il faut connaître la suivante

## Solution : considérer des directions A-conjuguées

### *The Method of Conjugate Directions*

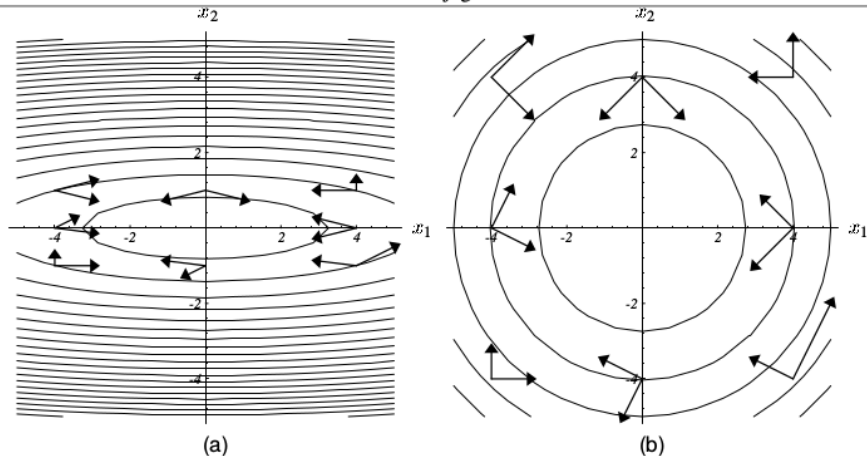


Figure 22: These pairs of vectors are  $A$ -orthogonal ... because these pairs of vectors are orthogonal.



## A-orthogonalisation de Gram-Schmidt

Soit  $u_i$   $i = 0, \dots, n - 1$  une base quelconque de  $\mathbb{R}^n$  et  $A \in \mathcal{M}_n(\mathbb{R})$  **symétrique définie positive**.

On considère le produit scalaire suivant ( $A$ -produit scalaire) :

$$\forall (x, y) \in (\mathbb{R}^n)^2, (x|y)_A = (x|A \cdot y)$$

On veut construire une nouvelle base  $d_i$   $i = 0, \dots, n - 1$  qui soit  $A$ -orthogonale i.e.  $\forall i \neq j, (d_i|d_j)_A = 0$

$$d_0 = u_0$$

$$d_1 = u_1 + \beta_{10} d_0$$

$$d_2 = u_2 + \beta_{20} d_0 + \beta_{21} d_1$$

$$d_{p+1} = u_{p+1} + \sum_{j=0}^p \beta_{p+1j} d_j$$

...

$$d_{n-1} = u_{n-1} + \sum_{j=0}^{n-2} \beta_{nj} d_j$$

## A-orthogonalisation de Gram-Schmidt – suite

$$d_{p+1} = u_{p+1} + \sum_{j=0}^p \beta_{p+1j} d_j$$

Calcul de  $d_{p+1}$  en supposant  $d_i, i = 0, \dots, p$  déjà calculés et  $\forall j \neq i, (d_j | d_i)_A = 0$  :

$$i = 0, \dots, p \quad (d_{p+1} | d_i)_A = (u_{p+1} | d_i)_A + \sum_{j=0}^p \beta_{p+1j} (d_j | d_i)_A$$

$$0 = (u_{p+1} | d_i)_A + \beta_{p+1i} (d_i | d_i)_A$$

D'où

$$\beta_{p+1i} = -\frac{(u_{p+1} | d_i)_A}{(d_i | d_i)_A} = -\frac{(u_{p+1} | A \cdot d_i)}{(d_i | A \cdot d_i)}$$

## Exercice 2 (avec nouvelles notations)

Soit à résoudre  $A \cdot x = b$  avec  $A \in \mathcal{M}_n(\mathbb{R})$  symétrique définie positive.

On note  $u_i$ ,  $i = 0, \dots, n-1$  les différentes colonnes de  $A$ .

Le procédé de  $A$ -orthogonalisation de Gram-Schmidt est appliqué à  $u_i$ ,  $i = 0, \dots, n-1$  pour construire une base  $d_i$ ,  $i = 0, \dots, n-1$   $A$ -orthogonale de  $\mathbb{R}^n$ .

1. Exprimer la solution du système  $A \cdot x^* = b$  dans la base  $d_i$ ,  $i = 0, \dots, n-1$ .

2. Montrer que  $\forall y \in \mathbb{R}^n, x^* = y + \sum_{i=0}^{n-1} \frac{(d_i | b - A \cdot y)}{(d_i | A \cdot d_i)} d_i$

3. On considère l'algorithme itératif suivant :

$$\forall x^{(0)} \in \mathbb{R}^n, x^{(p+1)} = x^{(p)} + \alpha_p d_p \text{ avec } \alpha_p = \frac{(d_p | b - A \cdot x^{(p)})}{(d_p | A \cdot d_p)}$$

3.1 Donner la relation entre  $x^{(p)}$  et  $x^{(0)}$

3.2 Montrer que pour  $p = 1, 2, 3, \dots$   $(d_p | A \cdot x^{(p)}) = (d_p | A \cdot x^{(0)})$

4. Montrer que l'algorithme de la question ci-dessus atteint exactement la solution du système  $A \cdot x^* = b$  en  $n$  itérations.

# Quelques propriétés

## Propriété 0 (question 3 de l'exercice)

$$p = 1, 2, 3, \dots, (d_p | A \cdot x^{(p)}) = (d_p | A \cdot x^{(0)}) \implies (d_p | r^{(p)}) = (d_p | r^{(0)})$$

## Propriété 1

$$j = 0, \dots, p-1, (r^{(p)} | d_j) = 0$$

## Propriété 2

$$j = 0, \dots, p-1, (r^{(p)} | u_j) = 0$$

## Propriété 3

$$(r^{(p)} | d_p) = (r^{(p)} | u_p)$$

## Mise en forme d'une itération de l'algorithme :

$$x^{(0)} = ?, \quad r^{(0)} = b - Ax^{(0)}$$

$\{u_i\}_{i=0,\dots,n-1}$  colonnes de  $A$

$$d_0 = u_0$$

Pour  $p = 0, n - 1$

$$\alpha_p = \frac{(d_p | r^{(p)})}{(d_p | A \cdot d_p)}$$

$$x^{(p+1)} = x^{(p)} + \alpha_p d_p$$

$$r^{(p+1)} = r^{(p)} - \alpha_p A \cdot d_p$$

$$\text{pour } j = 0, \dots, p, \quad \beta_{p+1j} = -\frac{(u_{p+1} | A \cdot d_j)}{(d_j | A \cdot d_j)}$$

$$d_{p+1} = u_{p+1} + \sum_{j=0}^p \beta_{p+1j} d_j$$

Fin Pour

Coût : mémoire, calcul ?

## Cas particulier du Gradient Conjugué

Soit  $u_i = r^{(i)}$ ,  $i = 0, \dots, n-1$

► 1ère conséquence :

$$\alpha_p = \frac{(d_p | r^{(p)})}{(d_p | A \cdot d_p)} = \frac{(r^{(p)} | r^{(p)})}{(d_p | A \cdot d_p)}$$

► 2ème conséquence :  $j = 0, \dots, p$

$$\beta_{p+1j} = -\frac{(u_{p+1} | A \cdot d_j)}{(d_j | A \cdot d_j)} = -\frac{(r^{(p+1)} | A \cdot d_j)}{(d_j | A \cdot d_j)}$$

D'autre part  $r^{(j+1)} = r^{(j)} - \alpha_j A \cdot d_j$

$$(r^{(p+1)} | r^{(j+1)}) = (r^{(p+1)} | r^{(j)}) - \alpha_j (r^{(p+1)} | A \cdot d_j)$$

et donc

$$\alpha_j (r^{(p+1)} | A \cdot d_j) = (r^{(p+1)} | r^{(j)}) - (r^{(p+1)} | r^{(j+1)})$$

## Cas particulier du gradient conjugué – suite

$$\alpha_j(r^{(p+1)}|A \cdot d_j) = (r^{(p+1)}|r^{(j)}) - (r^{(p+1)}|r^{(j+1)})$$

$j = p$

$$\begin{aligned}\alpha_p(r^{(p+1)}|A \cdot d_p) &= (r^{(p+1)}|r^{(p)}) - (r^{(p+1)}|r^{(p+1)}) \\ &= 0 - (r^{(p+1)}|r^{(p+1)}) \quad (\text{prop. 2})\end{aligned}$$

$$(r^{(p+1)}|A \cdot d_p) = -\frac{1}{\alpha_p}(r^{(p+1)}|r^{(p+1)})$$

$$(r^{(p+1)}|A \cdot d_p) = -\frac{(d_p|A \cdot d_p)}{(r^p|r^{(p)})}(r^{(p+1)}|r^{(p+1)})$$

$$-\frac{(r^{(p+1)}|A \cdot d_p)}{(d_p|A \cdot d_p)} = \frac{(r^{(p+1)}|r^{(p+1)})}{(r^p|r^{(p)})}$$

$$\implies \beta_{p+1p} = \frac{(r^{(p+1)}|r^{(p+1)})}{(r^p|r^{(p)})}$$

$j = 0, \dots, p-1$

$$\begin{aligned}\alpha_j(r^{(p+1)}|A \cdot d_j) &= (r^{(p+1)}|r^{(j)}) - (r^{(p+1)}|r^{(j+1)}) \\ &= 0 - 0 \quad (\text{prop. 2})\end{aligned}$$

$$\implies \beta_{p+1j} = \frac{(r^{(p+1)}|A \cdot d_j)}{(d_j|A \cdot d_j)} = 0$$

d'où l'expression de  $d_{p+1}$  :

$$d_{p+1} = r^{(p+1)} + \beta_{p+1p}d_p \quad \text{avec} \quad \beta_{p+1p} = \frac{(r^{(p+1)}|r^{(p+1)})}{(r^{(p)}|r^{(p)})}$$

# Algorithme final du Gradient Conjugué

$$x^{(0)} = ?, d^{(0)} = b - Ax^{(0)}, r^{(0)} = d^{(0)}, p = 0$$

Boucler

$$\alpha_p = \frac{(r^{(p)} | r^{(p)})}{(d_p | A \cdot d_p)}$$

$$x^{(p+1)} = x^{(p)} + \alpha_p d_p$$

$$r^{(p+1)} = r^{(p)} - \alpha_p A \cdot d_p$$

$$\beta_p = \beta_{p+1p} = \frac{(r^{(p+1)} | r^{(p+1)})}{(r^{(p)} | r^{(p)})}$$

$$d_{p+1} = r^{(p+1)} + \beta_p d_p$$

$$p = p + 1$$

Jusqu'à Convergence

Coût : mémoire, calcul ?

Convergence ?