Cinquième partie

Mémoire

Contenu de cette partie

Gestion des images mémoire des processus

- Gestion de la mémoire physique
- Mémoire virtuelle
  - principe
  - amélioration des performances
  - mémoire virtuelle comme medium de communication
    - partage de mémoire entre processus
    - couplage de fichiers en mémoire virtuelle
- Conclusion : synthèses
  - hiérarchie de mémoires
  - exécution des programmes en mémoire
- Exemples : Unix BSD, Solaris, Linux, Windows NT

Motivation : image mémoire d'un processus (Unix)

Pour le programmeur : image mémoire = zone mémoire (RAM)

- privée
- contiguë
- commençant à l'adresse 0
- bornée par la taille des adresses

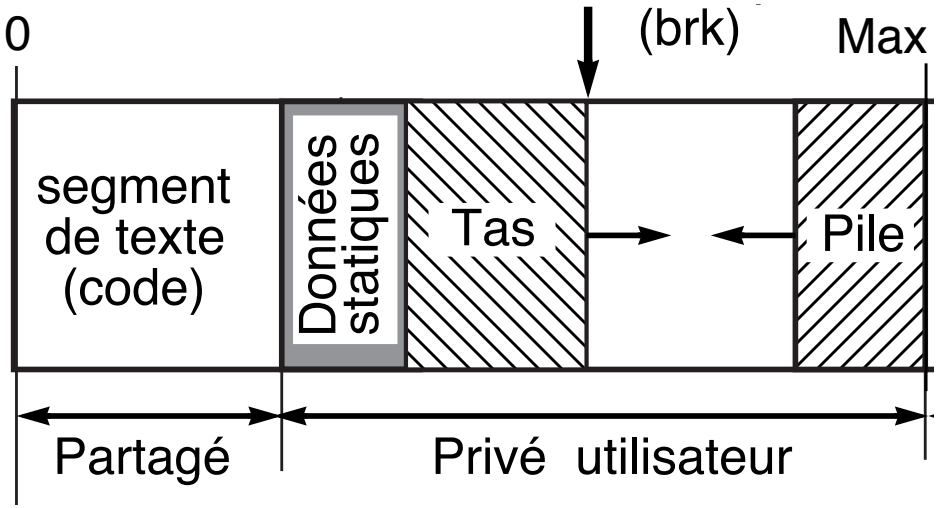

Objectif SX

Faire coexister plusieurs images mémoire dans une RAM

- partagée
- limitée en capacité

Plan

Partage physique de la mémoire entre processus

Allocation de blocs de mémoire contiguë

Solution directe

allouer à chaque processus un bloc (distinct) de mémoire,
de taille suffisante pour contenir son image mémoire

Partitions fixes *(OS 360 MFT)*

- La mémoire est divisée en zones de taille fixe (*partitions*).
- Une file d'attente est associée à chaque partition
- Quand un processus est lancé, le SX lui alloue la plus petite partition pouvant contenir son image mémoire (*best fit*)

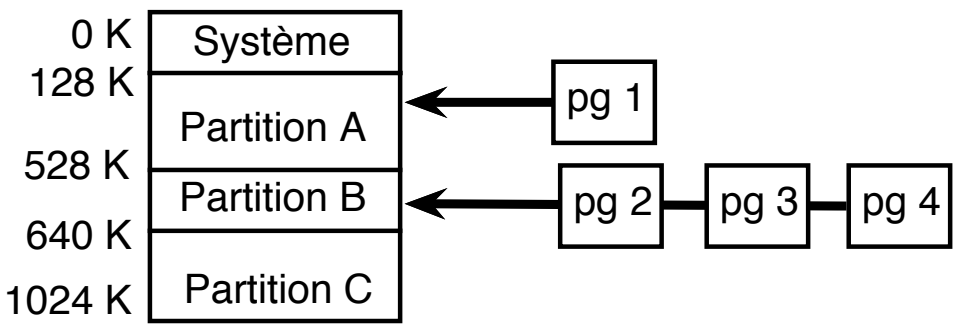

Avantage
Permet un va et vient efficace
(coexistence de processus prêts)

Problème : fragmentation interne
En général un processus utilisera seulement une partie de la mémoire allouée

Eviter la fragmentation interne

Eviter la fragmentation interne

→ ***Partitions variables***

- Allouer à chaque processus une partition de la taille exacte de son image mémoire
- En fin d'exécution, l'espace occupé est libéré

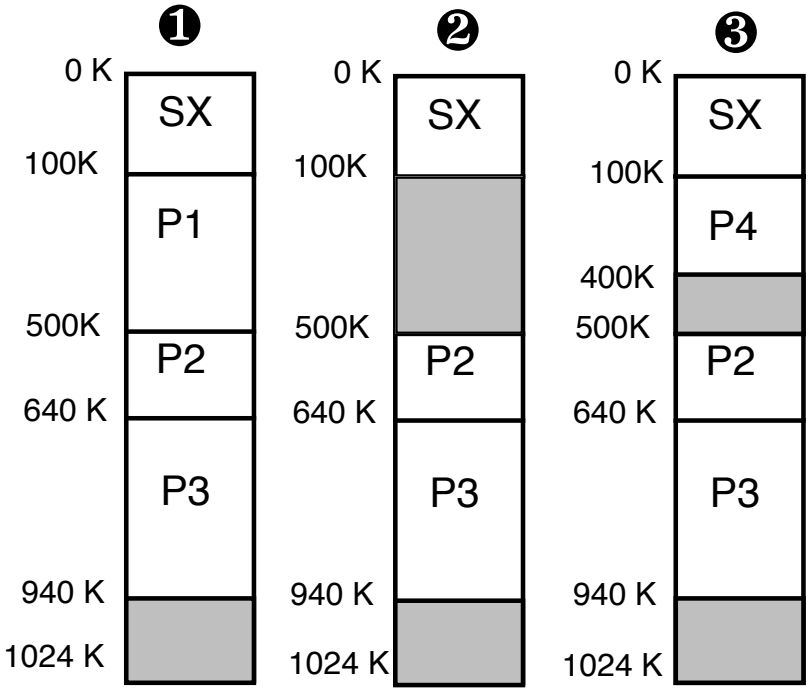

Politiques d'allocation de l'espace libre

Exemple : en ❷, P5 arrive, de taille 60K

- Plus grande zone disponible (*Worst-fit*)
  → implanter P5 à l'adresse 100K
- Plus petite zone possible
  («meilleur ajustement» ou *Best-fit*)
  → implanter P5 à l'adresse 940K
- Première zone possible (*First-fit*)
  → implanter P5 à l'adresse 100K

Eviter la fragmentation interne

→ ***Partitions variables***

- Allouer à chaque processus une partition de la taille exacte de son image mémoire
- En fin d'exécution, l'espace occupé est libéré

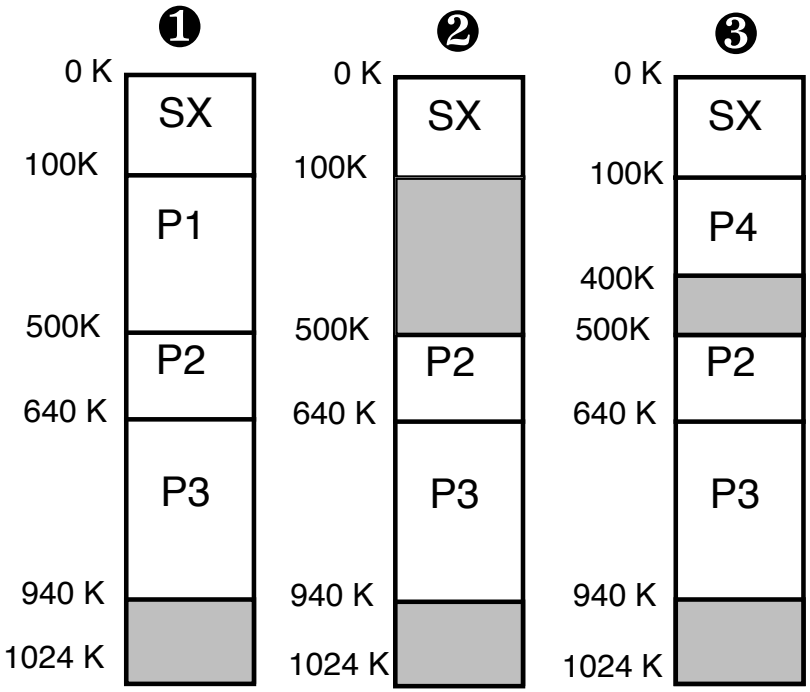

Politiques d'allocation de l'espace libre

Exemple : en ❷, P5 arrive, de taille 60K

- Plus grande zone disponible (*Worst-fit*)
  → implanter P5 à l'adresse 100K
- Plus petite zone possible
  («meilleur ajustement» ou *Best-fit*)
  → implanter P5 à l'adresse 940K
- Première zone possible (*First-fit*)
  → implanter P5 à l'adresse 100K

Meilleure politique ?

Partitions variables

Difficulté

Partitions variables

Difficulté : *fragmentation externe* (émiettement)

L'espace libre est suffisant, mais divisé en nombreux fragments de petite taille, inutilisables séparément (*miettes* (*garbage*))

Exemple : en ❸, que faire si P5 arrive, de taille 150K ?

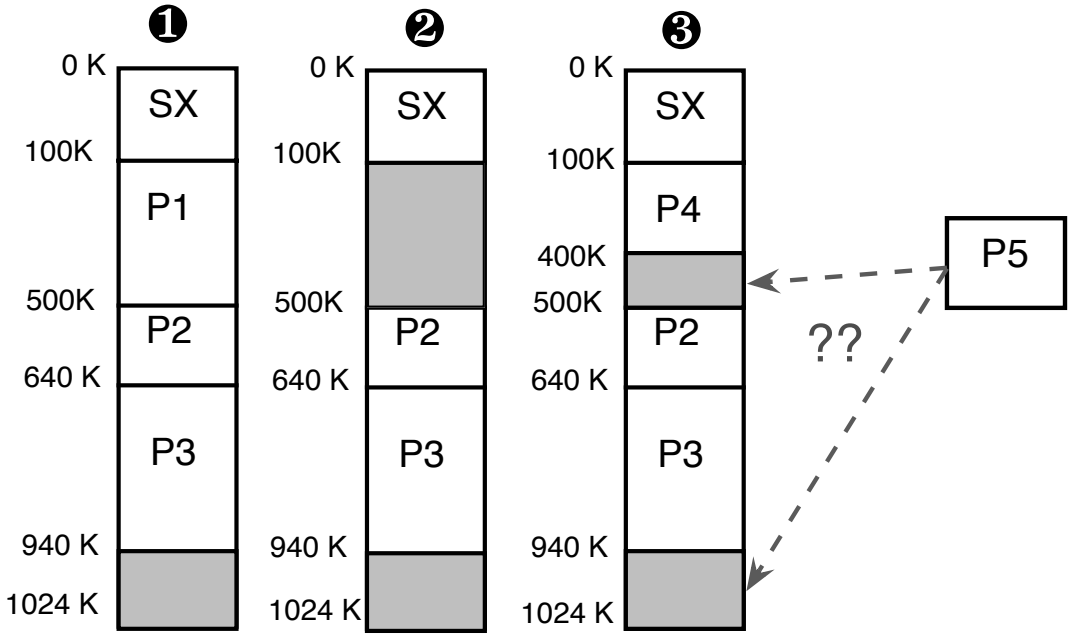

Partitions variables

Difficulté : *fragmentation externe* (émiettement)

L'espace libre est suffisant, mais divisé en nombreux fragments de petite taille, inutilisables séparément (*miettes* (*garbage*))

Exemple : en ❸, que faire si P5 arrive, de taille 150K ?

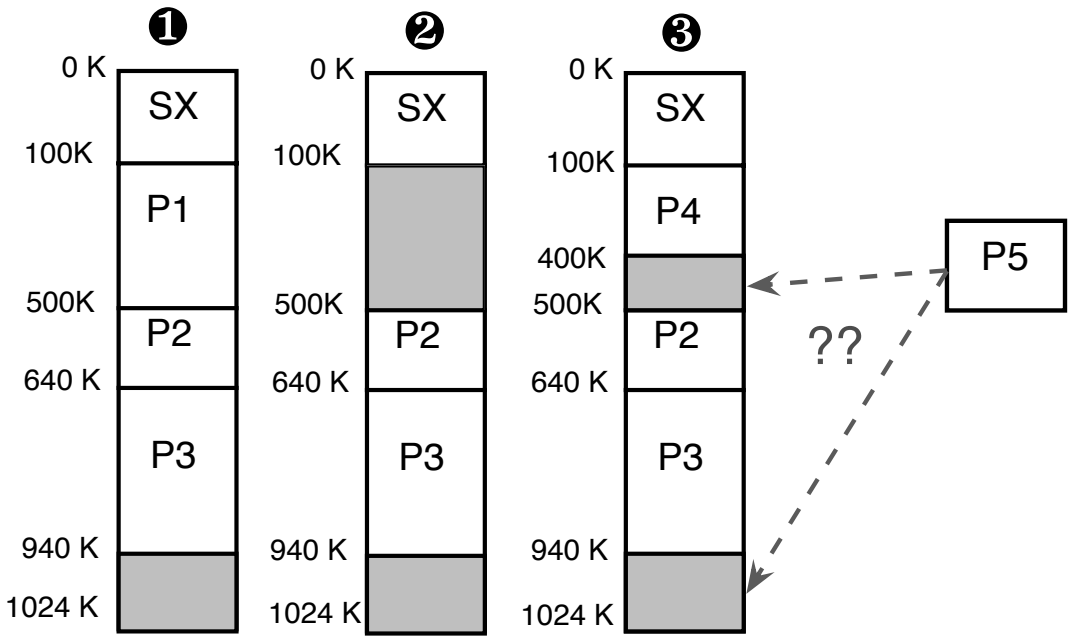

→ *(Re)compactage* : regrouper les zones libres en un seul bloc

⇒ recopie, réimplantation...

Bilan (provisoire)

Difficultés

- zones de taille fixe : manque de souplesse
  (tailles prédéfinies → fragmentation interne)
- zones de taille variable : fragmentation externe
  - recompactage : simple, mais coûteux en temps
  - traitement algorithmique :
    gérer les zones libres (recherche ; fusion de zones libres voisines)
    - lourd/complexe en général
      - table d'occupation de la mémoire (recherche lente, fusion ok)
      - listes de zones libres, classées par tailles (fusion lente)
    - possible lorsque l'ensemble des tailles demandées est régulier (puissances de 2) ou fixe (évite l'émiettement)
      Exemples : VM 370 (IBM) ; structures de données noyau Solaris

Intérêt

- d'éviter la fragmentation externe (zones fixes)

Bilan (provisoire)

Difficultés

- zones de taille fixe : manque de souplesse
  (tailles prédéfinies → fragmentation interne)
- zones de taille variable : fragmentation externe
  - recompactage : simple, mais coûteux en temps
  - traitement algorithmique :
    gérer les zones libres (recherche ; fusion de zones libres voisines)
    - lourd/complexe en général
      - table d'occupation de la mémoire (recherche lente, fusion ok)
      - listes de zones libres, classées par tailles (fusion lente)
    - possible lorsque l'ensemble des tailles demandées est régulier (puissances de 2) ou fixe (évite l'émiettement)
      Exemples : VM 370 (IBM) ; structures de données noyau Solaris

Intérêt

- d'éviter la fragmentation externe (zones fixes)
- de disposer d'un mécanisme d'allocation non contiguë...

Plan

Allocation fragmentée

Pagination (Allocation fragmentée de zones fixes)

Idée : fractionner l'image mémoire d'un processus
⇒ gérer une carte d'implantation de l'image mémoire (*table des pages*)

- L'image mémoire (virtuelle) est découpée en *pages*
- La mémoire physique est découpée en *cases*
- Cases et pages ont une taille P fixée et identique

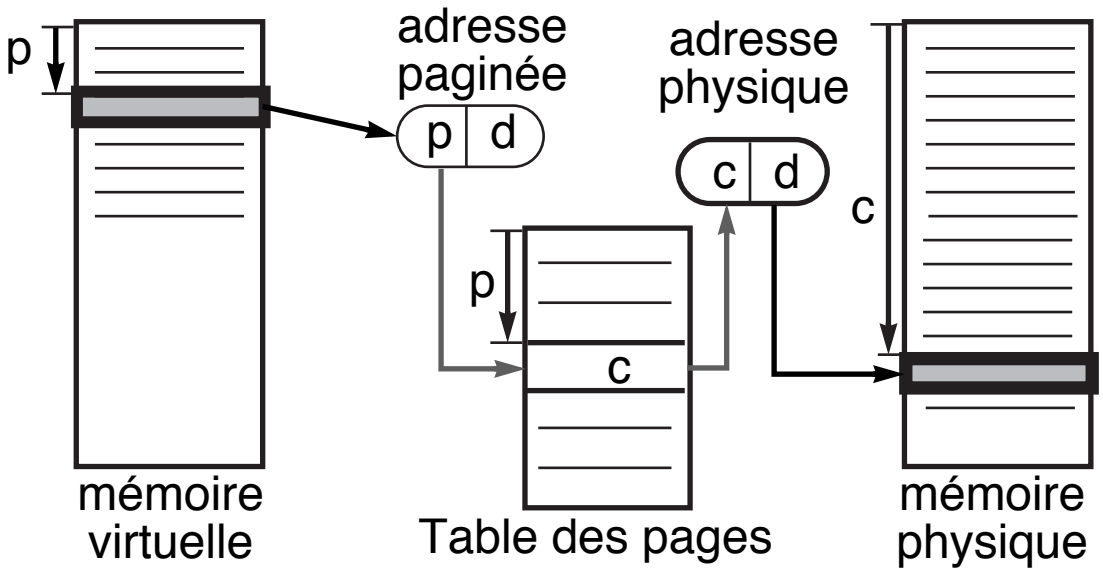

Evaluation de l'adresse virtuelle (Av)

A_v= (n° de page,déplacement dans la page) = (p,d),
avec p = A_v div P et d = A_v mod P (efficace avec P= 2^k)

Exemple

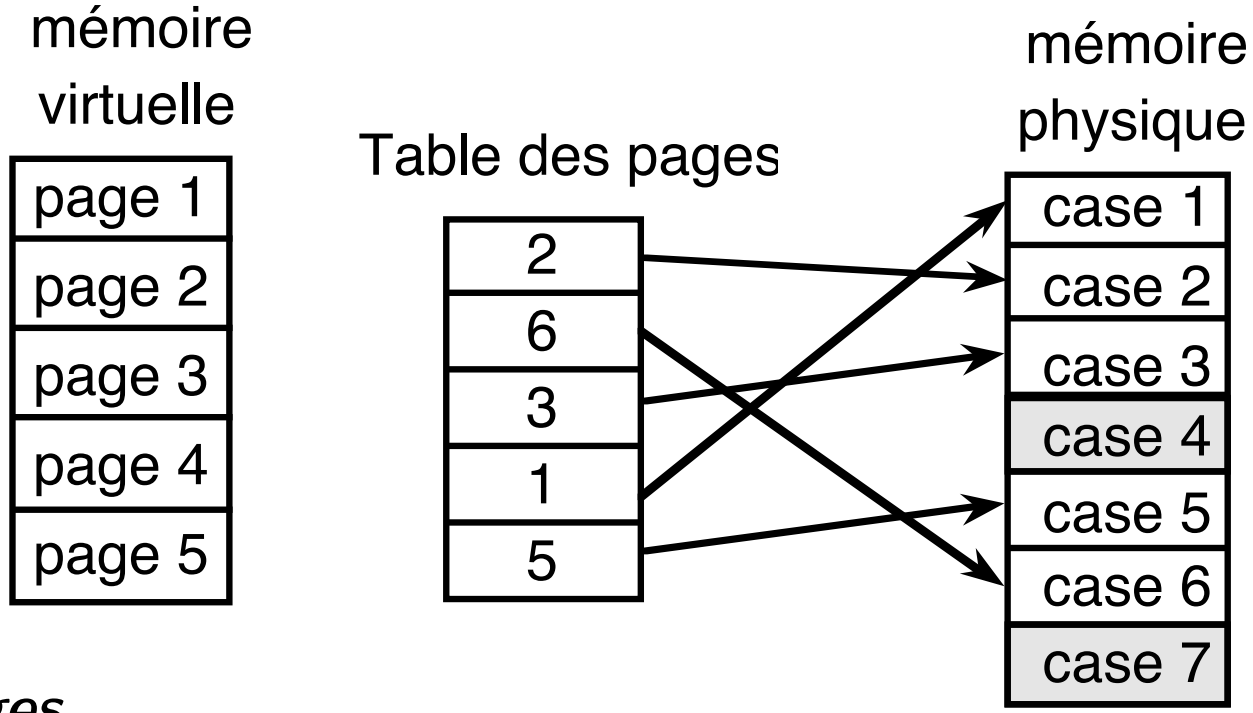

Avantages

- pas de fragmentation externe
- fragmentation interne : 1/2 page par processus, en moyenne
  $\rightarrow$ ok si la taille des pages est assez petite (souvent 2K-8K)

Exemple

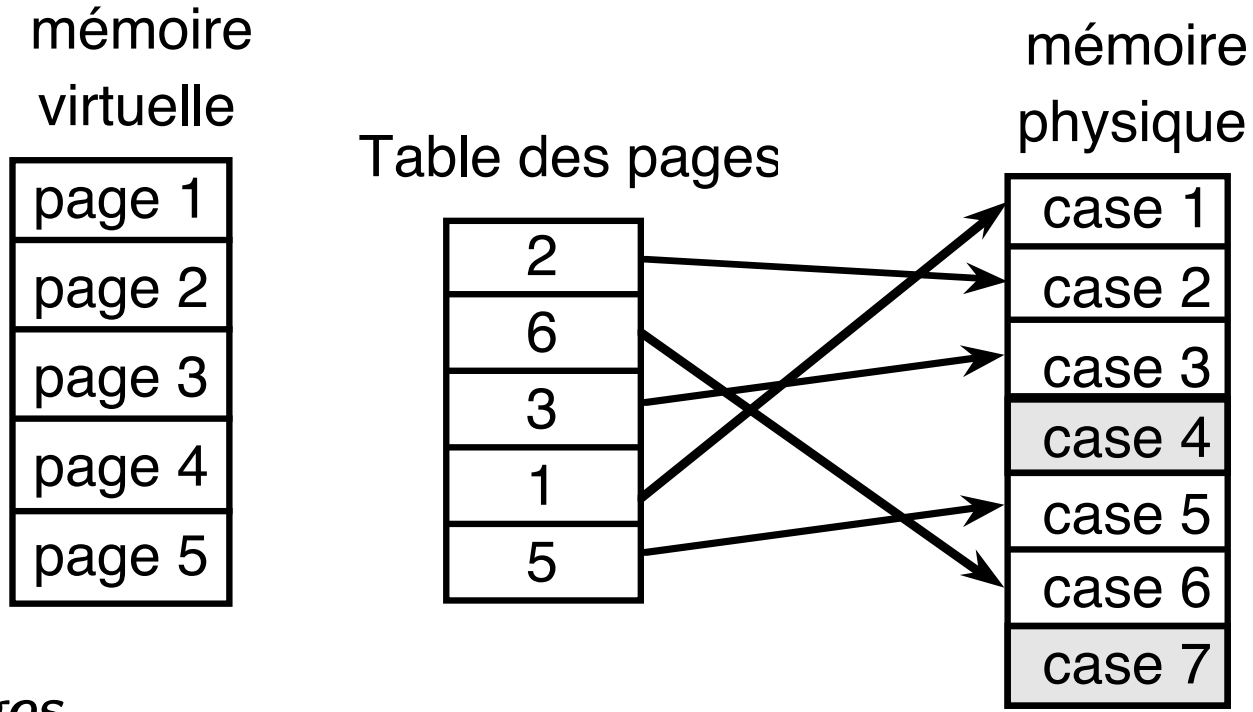

Avantages

- pas de fragmentation externe
- fragmentation interne : 1/2 page par processus, en moyenne
  $\rightarrow$ ok si la taille des pages est assez petite (souvent 2K-8K)
- (vu plus loin) interprétation des adresses (adressage indirect)
  $\rightarrow$ possibilité de
  - déplacer une page (réimplantation dynamique)
  - partager une page
  - contrôler l'accès à une page

Mise en œuvre efficace des tables des pages

Difficulté

En général, une table des pages par (image mémoire de) processus, référencée dans le descripteur du processus

Difficulté

Table des pages en RAM $\Rightarrow$ temps d'accès mémoire doublé
$\rightarrow$ mécanismes accélérateurs nécessaires

Idée naïve

conserver la table des pages en mémoire rapide (tableau de registres)

Mise en œuvre efficace des tables des pages

Difficulté

En général, une table des pages par (image mémoire de) processus, référencée dans le descripteur du processus

Difficulté

Table des pages en RAM $\Rightarrow$ temps d'accès mémoire doublé
$\rightarrow$ mécanismes accélérateurs nécessaires

Idée naïve
conserver la table des pages en mémoire rapide (tableau de registres)

Pourquoi naïve ?

Mise en œuvre efficace des tables des pages
Difficulté

En général, une table des pages par (image mémoire de) processus, référencée dans le descripteur du processus

Difficulté

Table des pages en RAM $\Rightarrow$ temps d'accès mémoire doublé
$\rightarrow$ mécanismes accélérateurs nécessaires

Idée naïve

conserver la table des pages en mémoire rapide (tableau de registres)

La taille d'une table des pages est importante
(adresses de 32 bits $\rightarrow$ espace de 4Gio, pages de 4Kio $\rightarrow 10^6$ pages)
$\rightarrow$ coût prohibitif

- matériel
- commutation de contexte

Mise en œuvre efficace des tables des pages (suite)

TLB (translation lookaside buffer)

→ mécanisme matériel spécifique :

registre associatif (TLB : translation lookaside buffer)

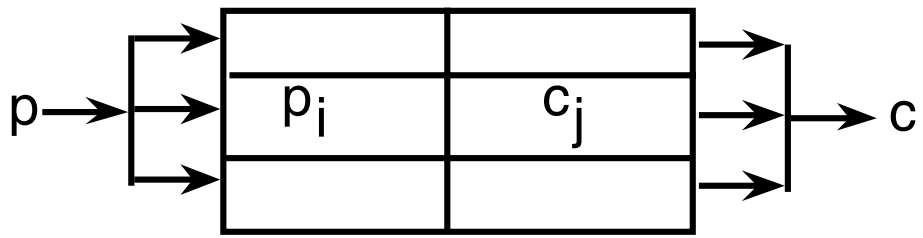

- contient les derniers accès (page → case) (LRU) : *principe de localité*
- recherche en parallèle
- en cas d'échec dans la recherche associative
  - On consulte la table complète (en mémoire)
  - On met le registre associatif à jour, avec la nouvelle référence
- LRU est une très bonne heuristique (mesures sur des applications types)

  16 entrées → 80% de succès, 32 (80486) → 98%, 512 → 99%, 4096 → 99,99%

Segmentation (Allocation fragmentée de zones variables)

Mémoire vue comme un ensemble de zones (*segments*)

- de longueurs variables
- sans ordre relatif

Idée

Un segment est destiné à contenir des objets de même « type »

→ possibilité de contrôles et protection adaptés au type :
Pour chaque segment

- contrôle des accès
  opérations possibles limitées aux opérations spécifiques au type des objets du segment
- contrôle de l'adressage
  Ex : si le segment contient un tableau, on conserve sa dimension

Mise en œuvre de la segmentation

Analogue à la pagination :

- Adresse segmentée : (id. segment, dépl. dans le segment)
- Mécanisme

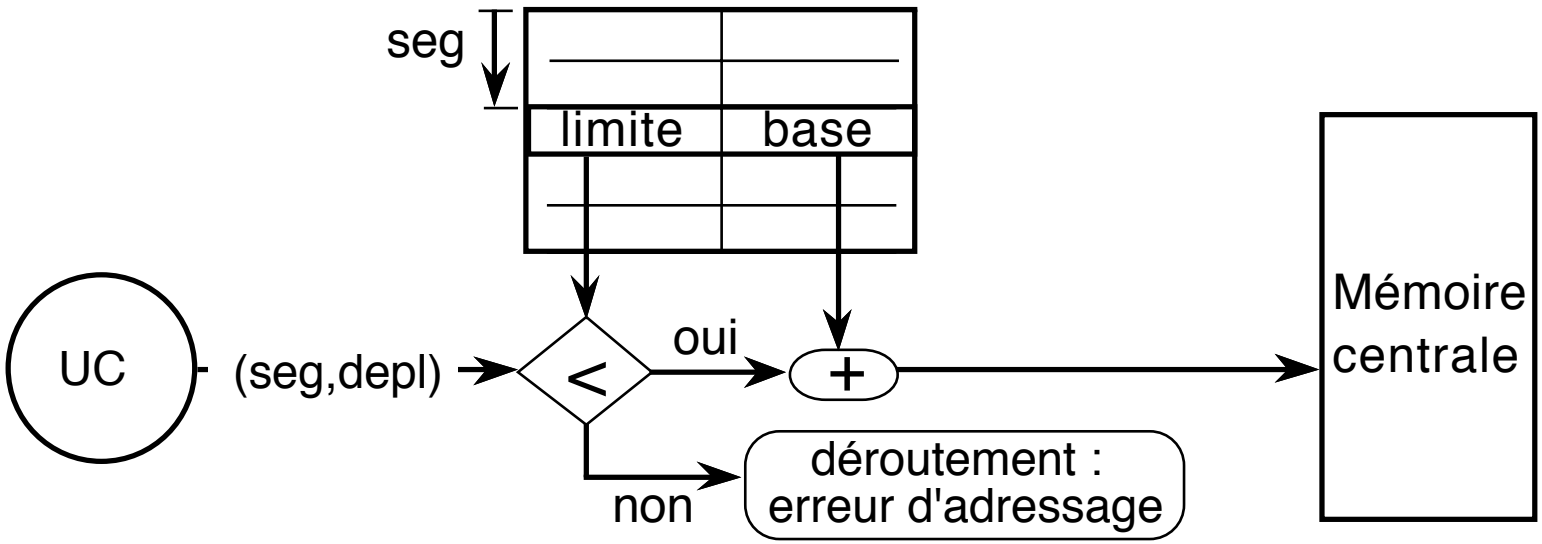

- Mise en œuvre de la table des segments

  cf table des pages : table en mémoire, registres associatifs

Différence : fragmentation externe

le recompactage est facilité (indirections), mais reste coûteux.

Segmentation paginée (Multics, 680x0)

- conserver l'abstraction offerte par la segmentation,
- ... sans la fragmentation externe

Segmentation paginée (Multics, 680x0)

- conserver l'abstraction offerte par la segmentation,
- ... sans la fragmentation externe

Idée : paginer les segments

- une table des segments pour chaque processus
- une table des pages pour chaque segment

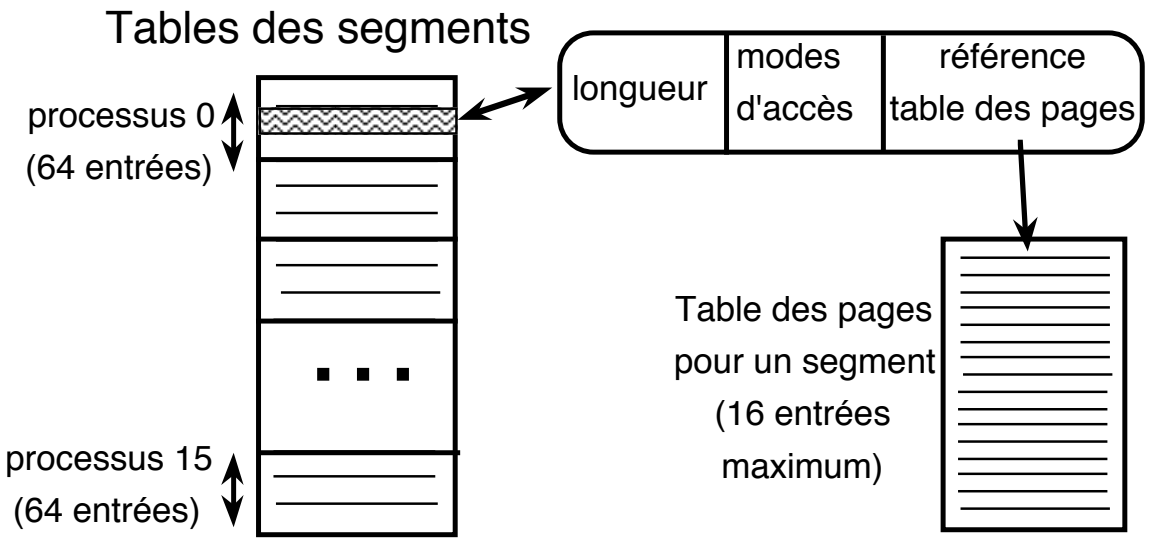

680x0 →
- 16 tables, pour 16 processsus (maximum)
- Chaque table de segments contient 64 entrées
- Chaque table de pages contient 16 entrées

Plan

Mémoire virtuelle

Problème : implanter un espace virtuel plus grand que l'espace réel

Solution directe : recouvrements (« overlays »)

Principe : indiquer (pragma) les procédures mutuellement indépendantes d'un programme (pas d'appel, ni d'imbrication)

Exemple : initialisation et reste du programme

→ de telles procédures peuvent être implantées à la même adresse (*se recouvrir*)

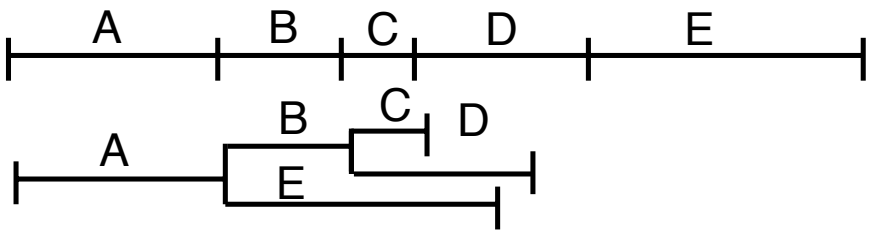

→ l'espace mémoire nécessaire au programme est réduit d'autant

Remarques

- A tout moment, un seul chemin de l'arbre est présent en mémoire
- Inconvénients :

Mémoire virtuelle

Problème : implanter un espace virtuel plus grand que l'espace réel

Solution directe : recouvrements (« overlays »)

Principe : indiquer (pragma) les procédures mutuellement indépendantes d'un programme (pas d'appel, ni d'imbrication)

Exemple : initialisation et reste du programme

→ de telles procédures peuvent être implantées à la même adresse (*se recouvrir*)

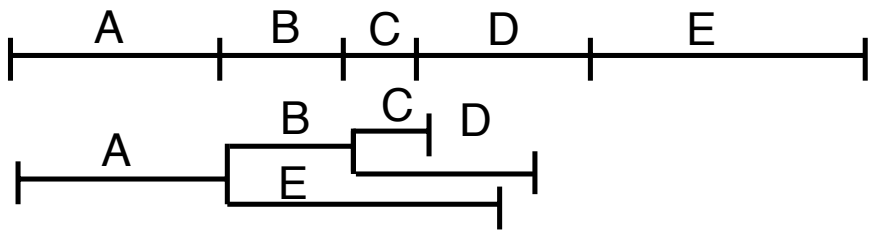

→ l'espace mémoire nécessaire au programme est réduit d'autant

Remarques

- A tout moment, un seul chemin de l'arbre est présent en mémoire
- Inconvénients : gestion explicite, ad hoc → limité

Va-et-vient (multiplexage temporel de la mémoire)

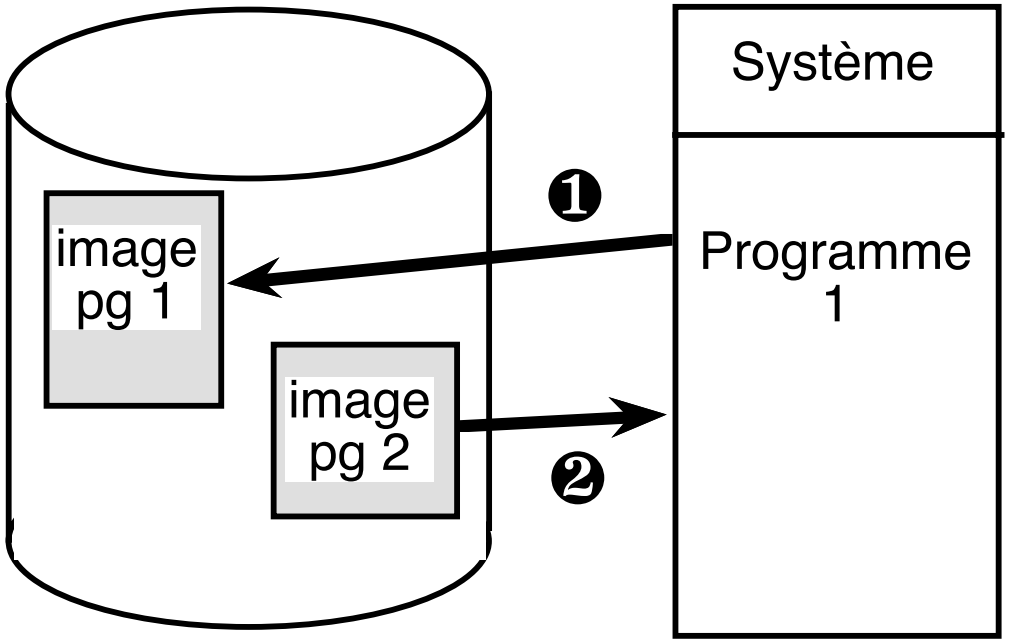

Une copie de l'image mémoire de chaque processus est conservée en mémoire secondaire

Pour changer l'occupant de la mémoire centrale :

1. Sauvegarde de l'image mémoire de l'élu courant
2. Restauration de l'image mémoire du nouvel élu

Intégration du va-et-vient et de la pagination

Idée : appliquer aux pages le principe du va-et-vient

→ *indicateur de présence* en mémoire pour chaque entrée de la table des pages

Principe de fonctionnement

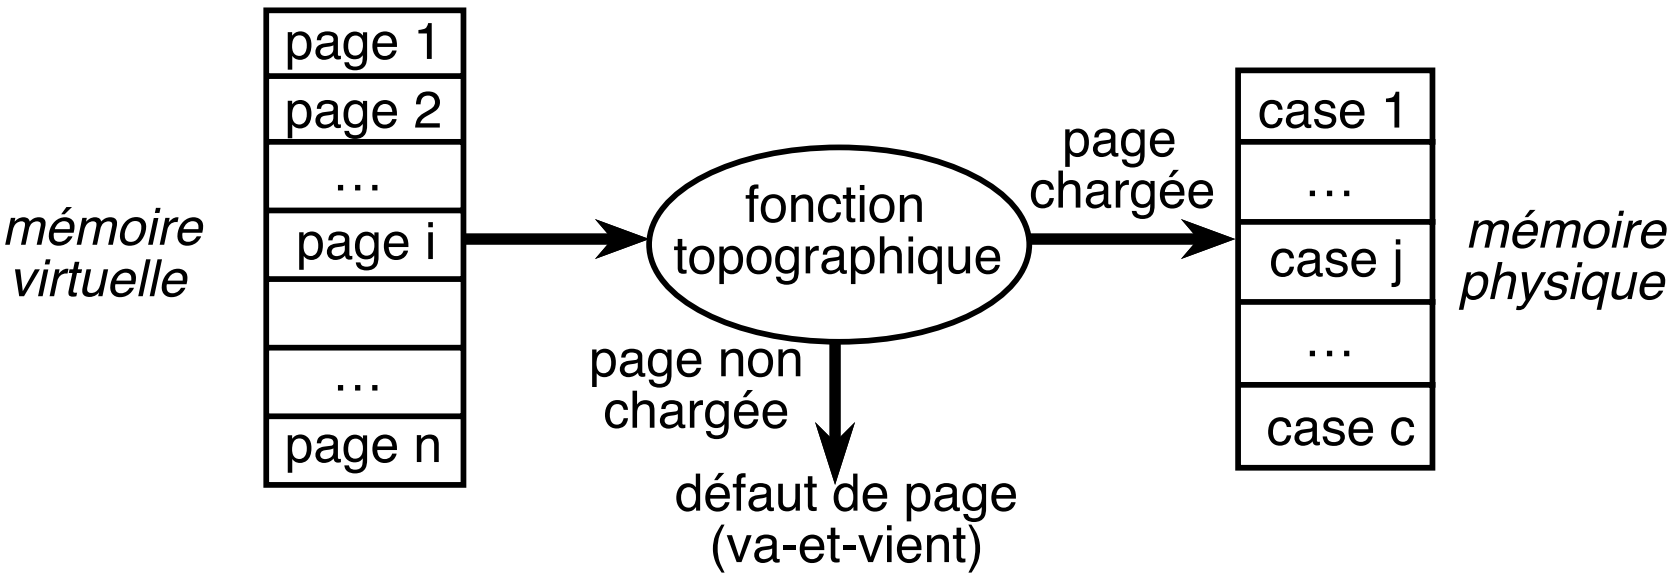

Remarques

- L'emploi de zones fixes simplifie le placement : cases équivalentes
- Fonction topographique = table des pages

Mécanisme de défaut de page (1/3)

Chargement

- ajout d'une colonne (*invalide*) à la table des pages, indiquant pour chaque page si elle est chargée en mémoire
- ajout d'une *table de couplage* <n° page, n° bloc> (colonne *bloc*), qui localise la copie de chaque page en mémoire secondaire (taille blocs (disque) = taille pages)

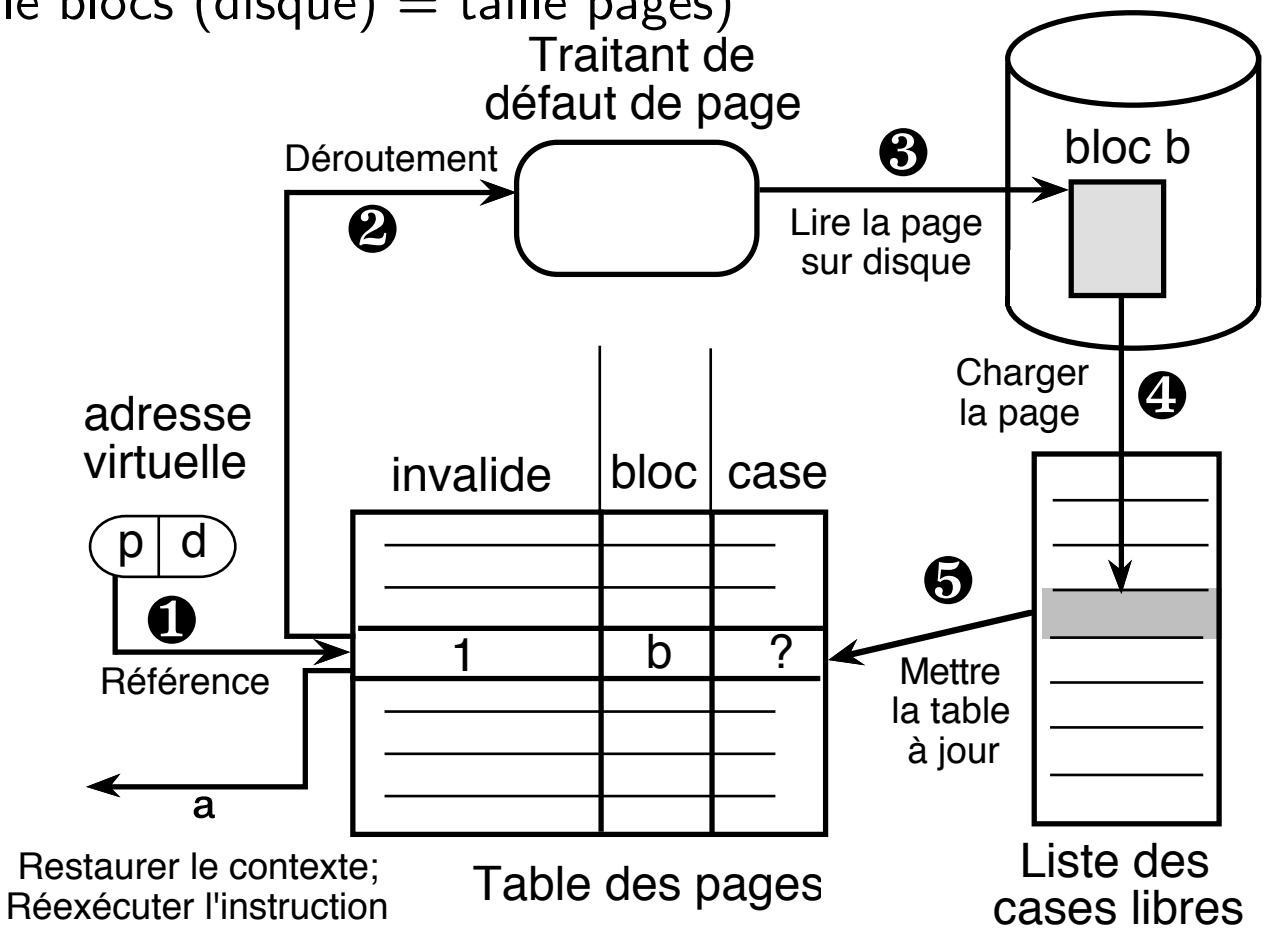

Mécanisme de défaut de page (2/3)

Remplacement

Va-et-vient « page à page » s'il n'y a plus de cases libres

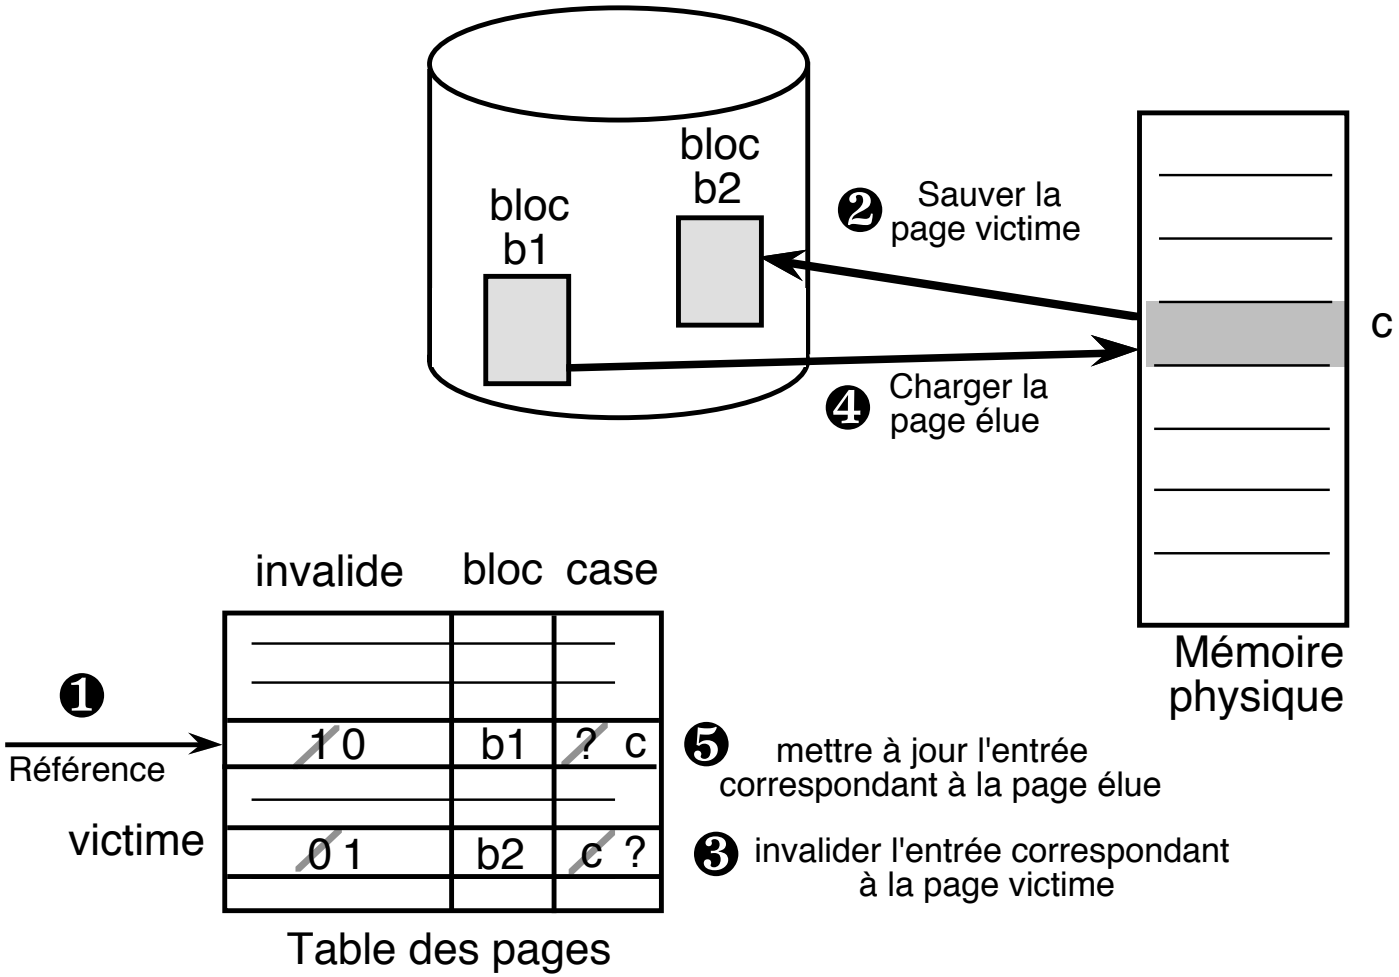

Remarque : le nombre d'E/S causées par un défaut de page double

Mécanisme de défaut de page (3/3)

Optimisation : mémoire associative (Translation Lookaside Buffer–TLB)

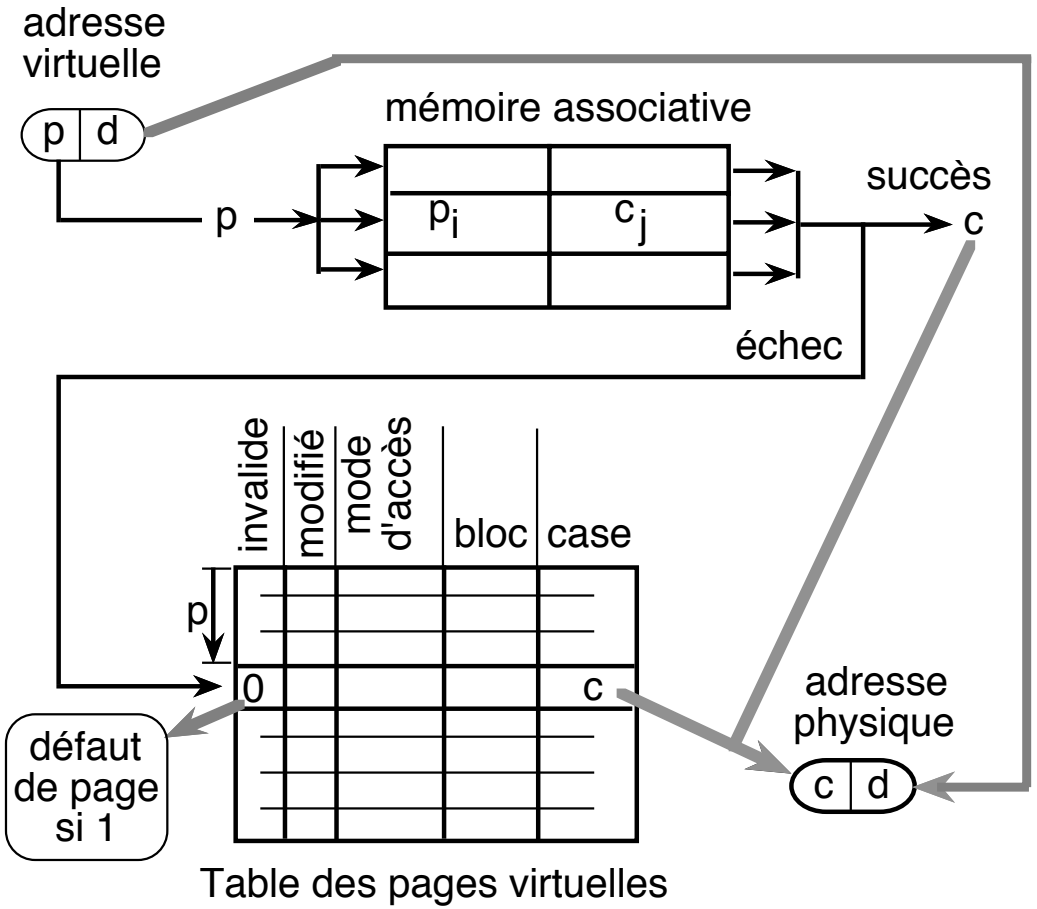

- *invalide* : bit de présence (faux si page en mémoire)
- *modifié* (“dirty bit”) : indique si une écriture a été effectuée sur la page (utilisé pour le remplacement)
- *mode d'accès* : opérations autorisées / la page (utilisé pour la protection)

Plan

Mise en œuvre d'un grand espace virtuel (1/3)

Difficulté : taille potentielle de la table des pages

Solution1 : liste inverse de pages (liste de cases)

Liste par case : < id de processus, n° de page >

- liste des cases réduite → accès séquentiel
- sinon, accès calculé (fonction de dispersion)
- usage courant d'une mémoire associative

Mise en œuvre d'un grand espace virtuel (2/3)

Solution 2 : pagination hiérarchique (hyperpages)

Idée : paginer la table des pages

- la table des pages est découpée en *hyperpages*
- la table des hyperpages (THP) permet de ne désigner que les parties de la table des pages effectivement utilisées
  $\rightarrow$ un compteur "nombre de pages désignées"
  est associé à chaque entrée de la THP
- adresse virtuelle = <n° hyperpage, n° page, déplacement>

Efficacité

- Mémoire associative nécessaire
- La table des hyperpages doit toujours rester en mémoire

Mise en œuvre d'un grand espace virtuel(3/3)

Pagination à 2 niveaux (S. Krakowiak, *principes des systèmes d'exploitation* (Dunod), p362))

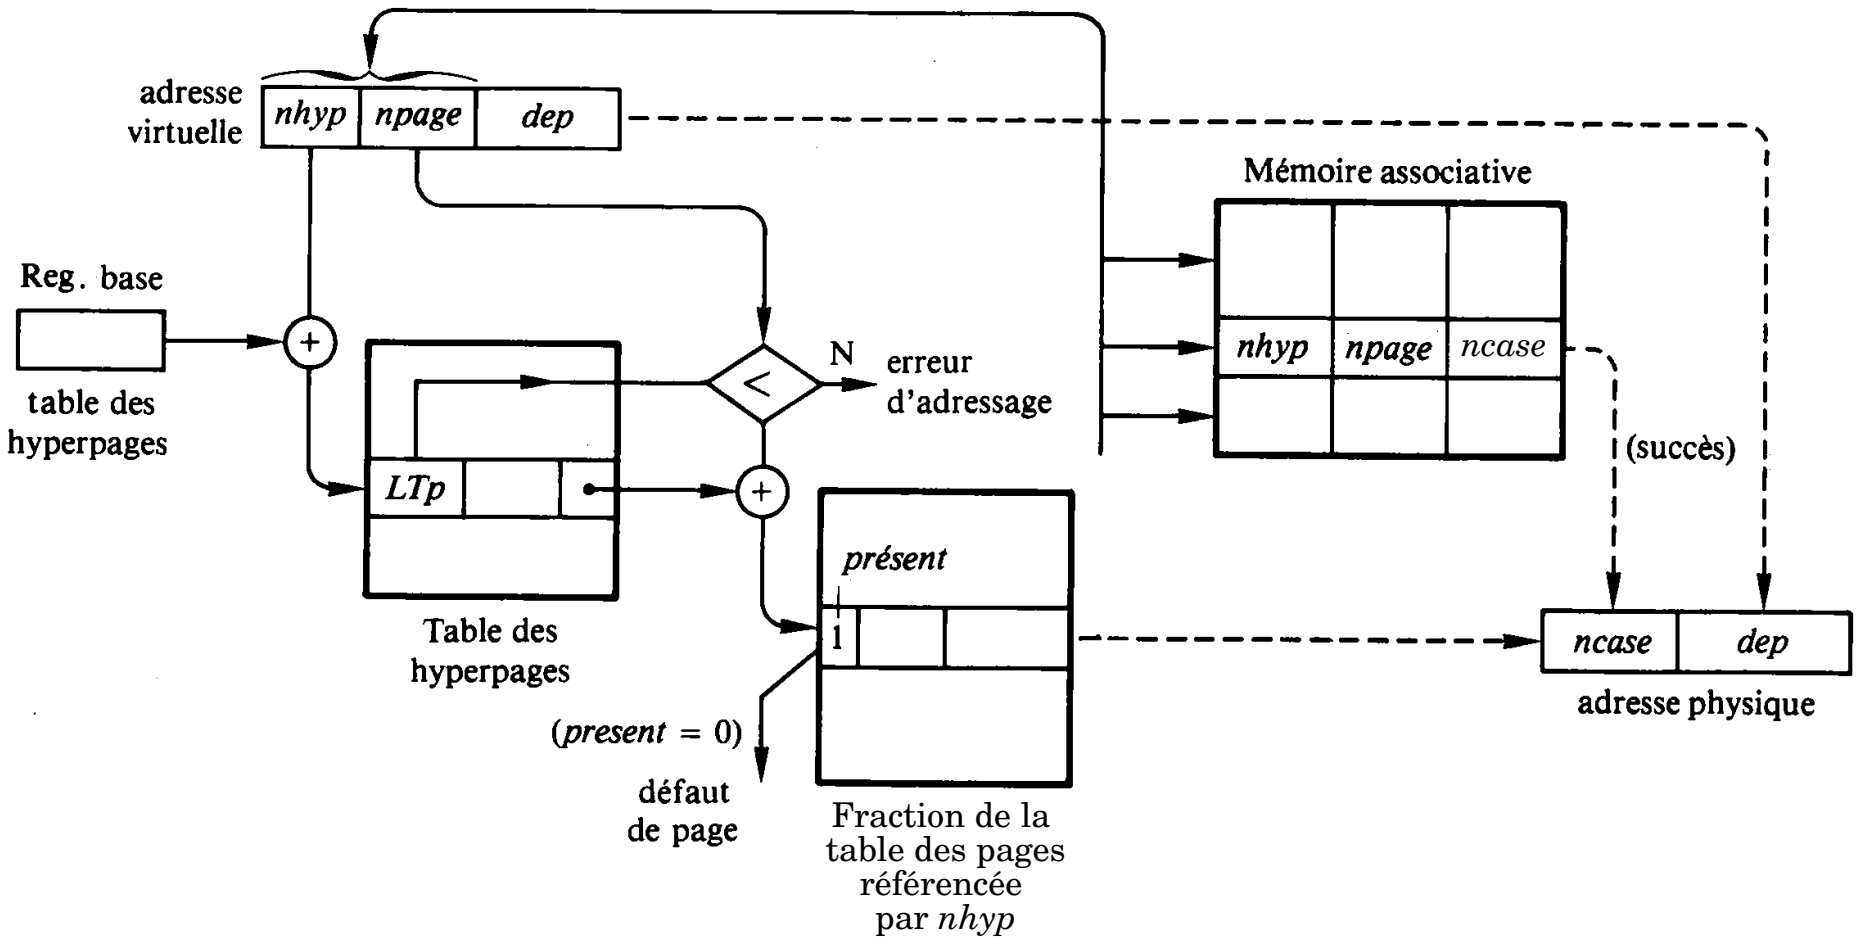

Ce principe peut être réitéré → hiérarchie d'hyperpages (Linux : 3 niveaux prévus)

Plan

Gestion de la mémoire virtuelle

Motivation : coût des défauts de page

Temps d'accès effectif à la mémoire

$$\boxed{\text{TAE} = (1\text{-p}) \times \text{TAM} + \text{p} \times \text{TDP}}$$

avec :

- p : probabilité d'un défaut de page ;
- TAM : temps d'accès mémoire
- TDP : temps d'accès, en cas de défaut de page (gestion de l'IT + va et vient)

Ordres de grandeur

- TAM $\approx$ 100 ns
- TDP $\approx$ 1 ms + 2*8ms $\approx$ 17 ms

$\rightarrow$ TAE $\approx 100 + 17\ 10^6\ p$

Pour avoir une dégradation des performances $\leq$ 10% de TAM, on doit avoir : $100 + 17\ 10^6\ p \leq 110$
soit : $p \leq 1 / 1{,}7\ 10^6$

Comment améliorer les performances de la mémoire virtuelle ?

Peaufiner le mécanisme

- éviter les lectures/écritures disque superflues
  - *bit d'utilisation* (*dirty bit*) : indique si la page victime a été modifiée (auquel cas elle doit effectivement être recopiée)
  - pool de *pages libres et sales* (utiliséees auparavant)
    → mémoriser le numéro des pages libérées
    → (localité) peut éviter un va-et-vient lors d'un défaut de page
- anticiper
  - pool de pages libres : évite d'attendre la sauvegarde de la victime
  - préchargement de pages : souvent possible et efficace (localité/ensemble de travail)
  - restitution volontaire de page : ok si automatique (compilateur)

Choisir la bonne victime

→ algorithmes de remplacement

Ecarter les processus causant trop de défauts de pages

→ régulation basée sur un modèle de comportement des processus

Choix des pages victimes : algorithmes de remplacement

Évaluation du comportement d'un processus en fonction de la mémoire disponible

- c(m,Ω) : *nombre de chargements de pages* causés par Ω
  - Ω : suite de références (numéros de pages virtuelles demandées par le processus),
  - m : nombre de pages mémoire disponibles pour le processus

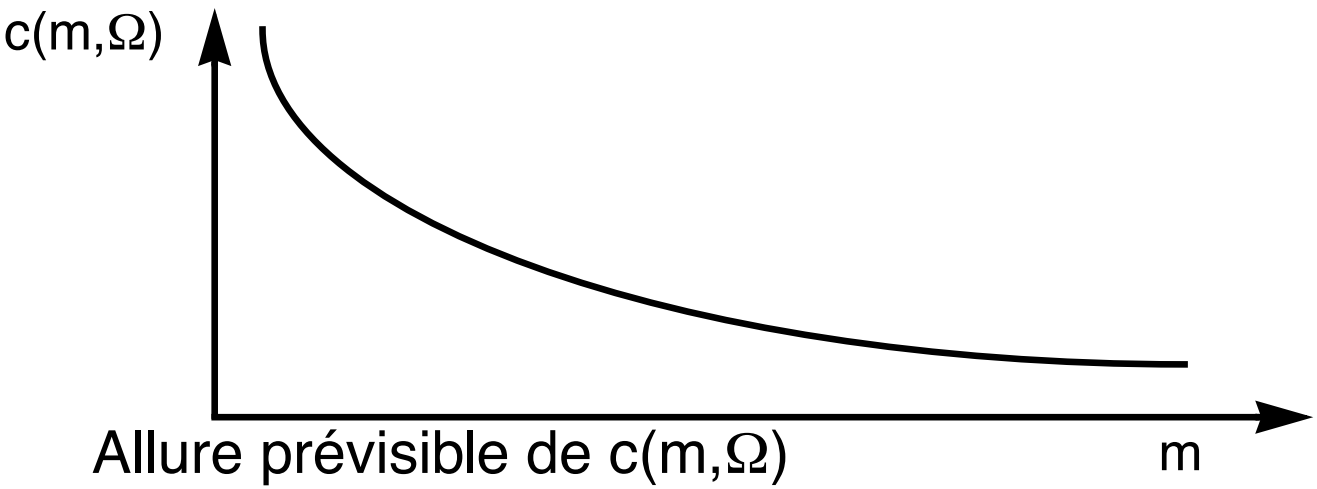

- *taux de défaut de pages* F= c(m,Ω)/|Ω|
  avec |Ω| : longueur de la suite de références

Algorithmes de remplacement

Algorithme aléatoire

Victime = page choisie aléatoirement

FIFO

Victime = première page chargée (parmi les pages présentes)

Remarque : l'allure de $c(m,\Omega)$ peut être contre-intuitive pour FIFO

Exemple (anomalie de Belady) :

- gestion FIFO des requêtes de remplacement
- Pour $\Omega = 1,2,3,4,1,2,5,1,2,3,4,5$ on a : $c(3,\Omega) < c(4,\Omega)$

Algorithmes de remplacement

Algorithme aléatoire

Victime = page choisie aléatoirement

FIFO

Victime = première page chargée (parmi les pages présentes)

Remarque : l'allure de $c(m,\Omega)$ peut être contre-intuitive pour FIFO

Exemple (anomalie de Belady) :

- gestion FIFO des requêtes de remplacement
- Pour $\Omega = 1,2,3,4,1,2,5,1,2,3,4,5$ on a : $c(3,\Omega) < c(4,\Omega)$

Algorithme optimal

Victime = page dont la prochaine utilisation est la plus tardive

$\Rightarrow$ évaluer a priori la chaîne des références

$\rightarrow$ irréalisable en général

Approximation de la solution optimale

Ordre chronologique d'accès (LRU , Least Recently Used)

Heuristique : localité temporelle

Le passé récent est une bonne image du futur proche

→ base pour évaluer le futur

→ LRU : victime = page inutilisée depuis le plus longtemps

Remarques

- LRU ne présente pas l'anomalie de Belady
- Mise en œuvre directe coûteuse (activée à chaque référence)
  - gérer une *liste* doublement chaînée.
    Fonctionnement
    - à chaque nouvelle référence, placer la page référencée en tête
    - victime = queue
  - numéroter les références successives
    → associer un compteur (*date logique*) à chaque page
    Difficultés : débordement du compteur, arithmétique, tri

Mises en œuvre approchées de LRU

utilisent un indicateur (bit) de référence associé à chaque page
(0 initialement, mis à 1 lors de l'accès)

Représentation « économique » des dates logiques

Date logique = historique des bits de référence sur une période de temps

- le bit de gauche est le bit de référence courant
- le mot est décalé vers la droite, à intervalles réguliers
- la plus petite valeur correspond à l'accès le moins récent

0	0	1	1	
0	1	0	0	
0	1	1	0	
0	0	0	1	
0	0	0	0	

Mises en œuvre approchées de LRU

utilisent un indicateur (bit) de référence associé à chaque page
(0 initialement, mis à 1 lors de l'accès)

Représentation « économique » des dates logiques

Date logique = historique des bits de référence sur une période de temps

- le bit de gauche est le bit de référence courant
- le mot est décalé vers la droite, à intervalles réguliers
- la plus petite valeur correspond à l'accès le moins récent

0	0	1	1	
0	1	0	0	
0	1	1	0	
0	0	0	1	
0	0	0	0	

Algorithme de la deuxième chance

- Index parcourant la table des pages de manière circulaire
- L'entrée pointée de la table des page a un bit de référence valant
  - 1 → bit remis à 0 ; l'index progresse
  - 0 → c'est la victime

Conclusion

Évaluation des différents algorithmes

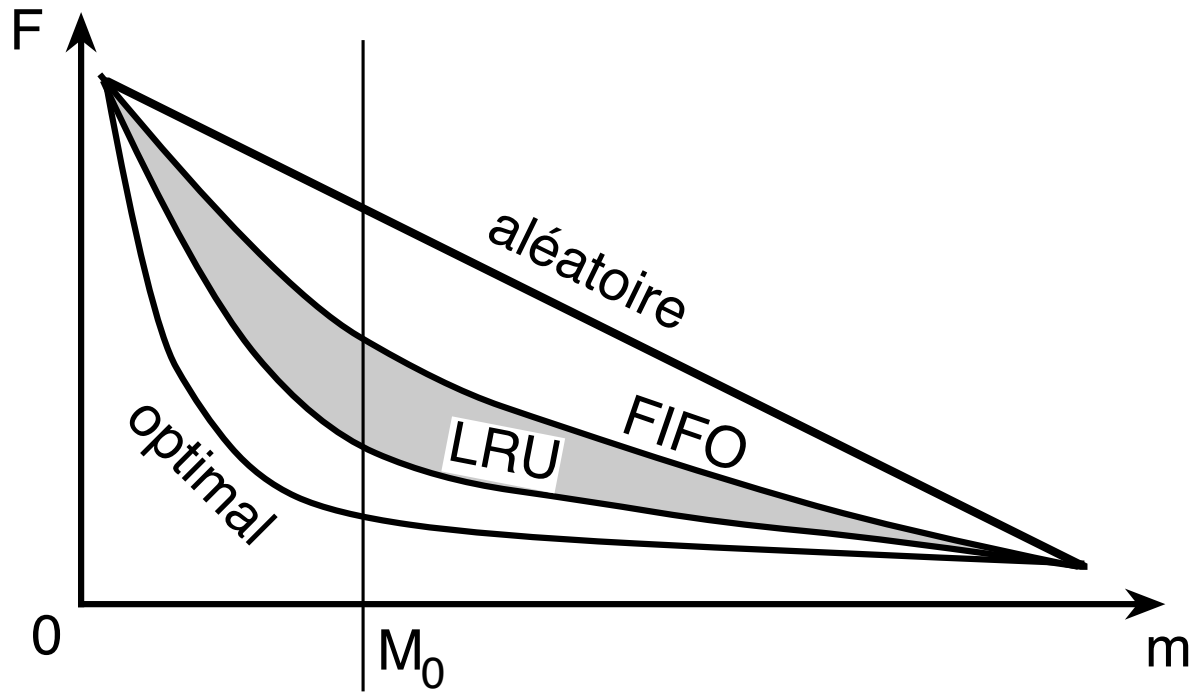

Point saillant : existence d'un seuil M_0 à partir duquel F croît très vite

- avant ce seuil, les performances s'améliorent nettement avec m
- après ce seuil, augmenter m est peu rentable

Conclusion

Évaluation des différents algorithmes

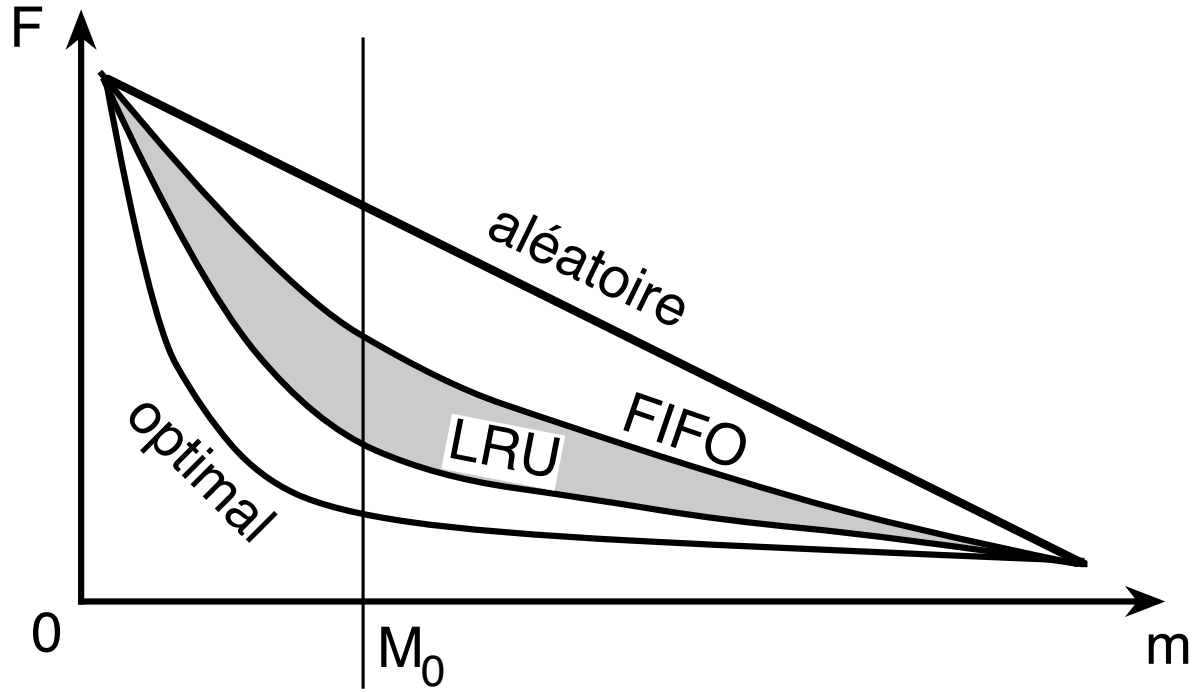

Point saillant : existence d'un seuil M_0 à partir duquel F croît très vite

- avant ce seuil, les performances s'améliorent nettement avec m
- après ce seuil, augmenter m est peu rentable

Moralité

L'algorithme compte moins que la taille de la mémoire allouée

Stratégies de régulation

Modèle de comportement d'un programme : ensemble de travail [Denning]

Essentiel : fournir un espace suffisant à chaque processus

Espace suffisant déterminé à partir de 2 heuristiques de localité

- *temporelle* : sur une (courte) période d'observation, l'ensemble des pages utilisées est stable
- *spaciale* : les références se concentrent sur peu de pages
  valeurs usuelles : 75% des accès portent sur 20% des adresses

→ notion d'*ensemble de travail* ("*working set*") :
pages référencées par un processus, sur une période de temps

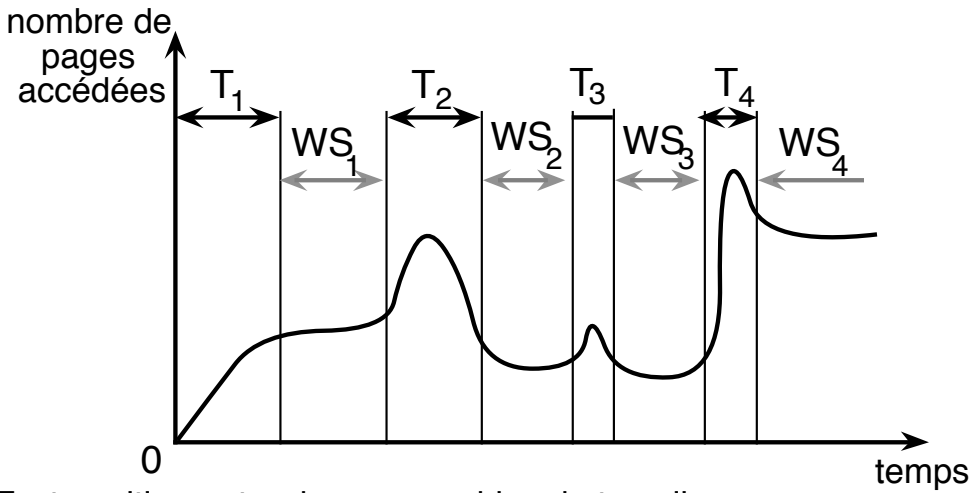

T_i : transition entre deux ensembles de travail
WS_j : ensemble de travail

Illustration expérimentale [Hatfield 1972 – IBM Syst. Journal]

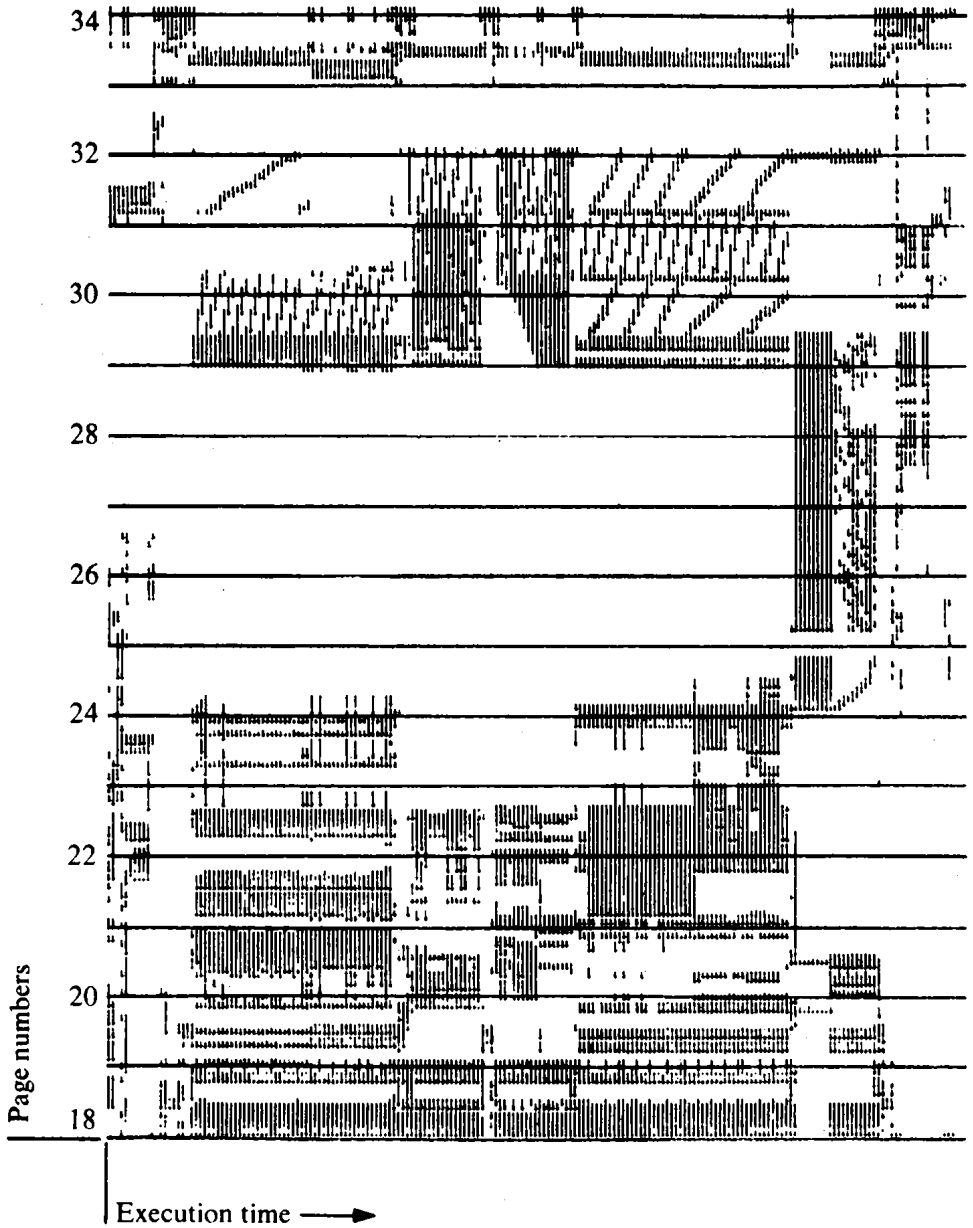

Illustration empirique : écroulement du système (“trashing”)

Phénomène observé

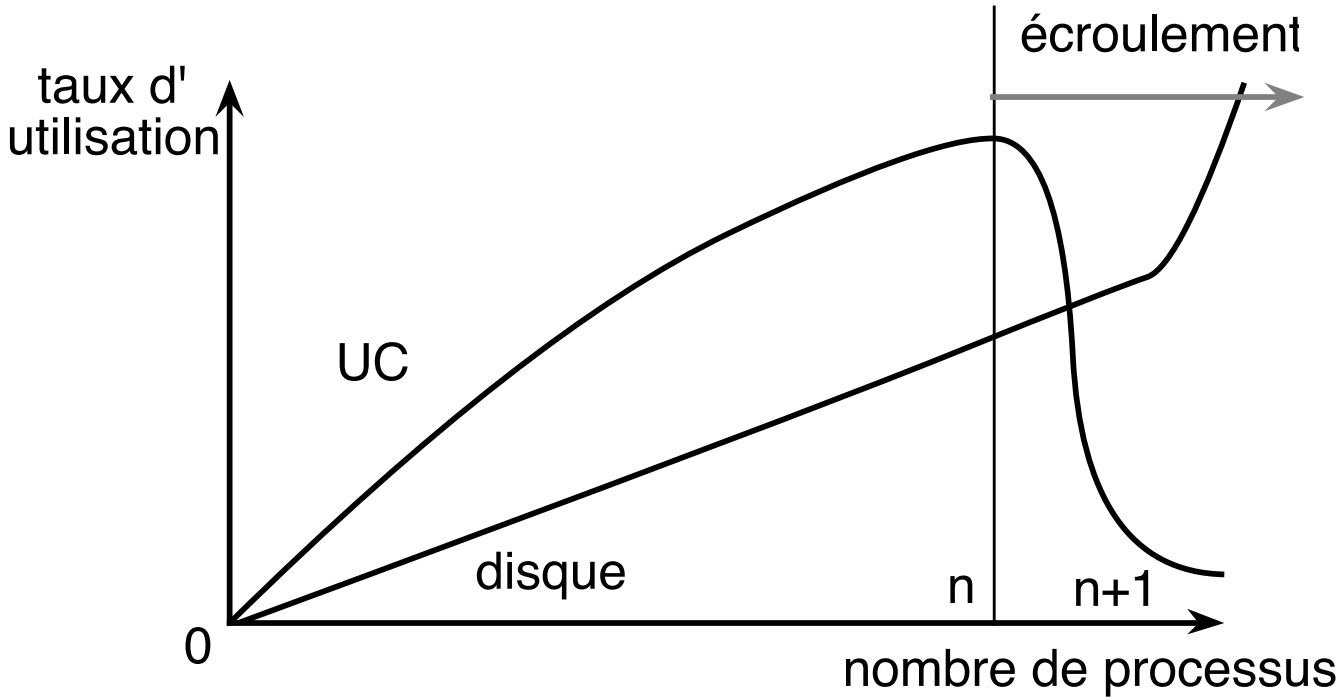

Explication

Dès qu’un processus a moins de mémoire que son ensemble de travail
→ il engendre des défauts de pages nombreux et fréquents
→ s’il n’y a plus de cases libres, retrait de pages à d’autres processus qui, à leur tour, ne disposent plus de leur ensemble de travail. . .
→ boule de neige

Algorithmes basés sur le modèle de comportement

Idée

Prévenir l'écroulement en limitant le nombre de processus prêts (actifs)

Algorithme de l'ensemble de travail (WS)

- l'ensemble de travail de chaque processus est mémorisé
- en cas de défaut de page
  - on remplace une page qui n'est dans aucun ensemble de travail
  - s'il n'y en a pas, on réquisitionne les pages détenues par le processus le moins prioritaire (qui est suspendu)

  → tout processus actif dispose des pages de son ensemble de travail

Exemple : VMS (VAX)

relevé périodique des bits de référence pour estimer l'ensemble de travail

Algorithmes basés sur le modèle de comportement (suite)

Algorithme du taux de défaut de page par processus (PFF, page fault frequency)

Idée

Utiliser le taux de défauts de page pour détecter si un processus dispose de son espace de travail

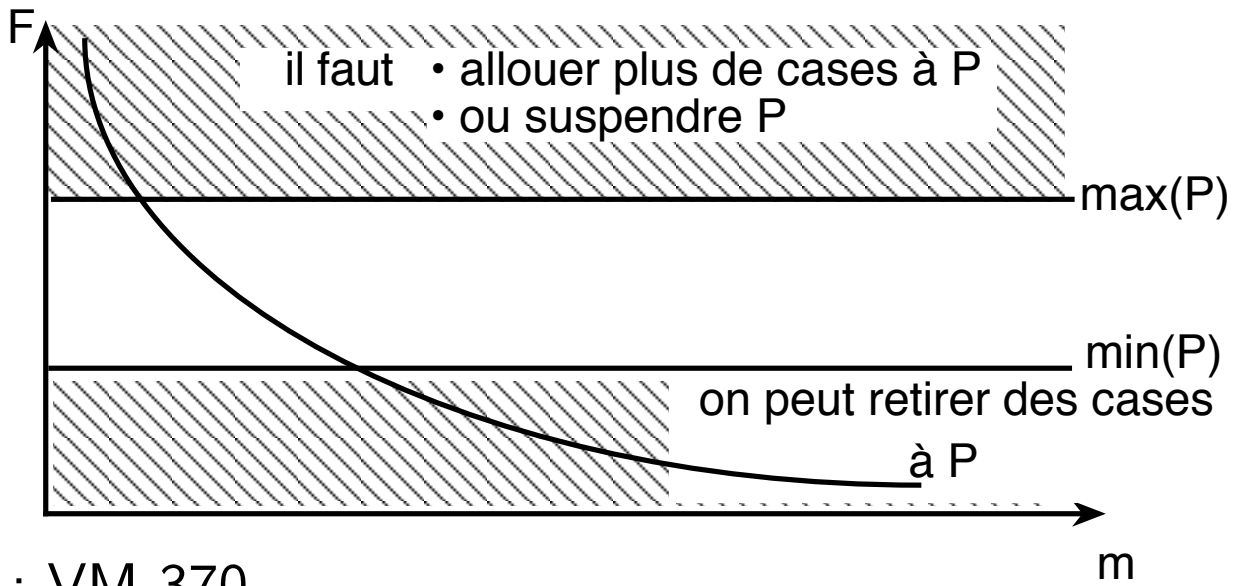

Exemple : VM 370

Remarques

- PFF est plus aisé à réaliser que WS
- Les capacités mémoire actuelles permettent (et ont pour objectif) de réduire très fortement le va-et-vient, et donc l'écroulement.

Plan

Partage de pages entre processus

Principe

Référencer une même case mémoire à partir de pages distinctes de processus distincts

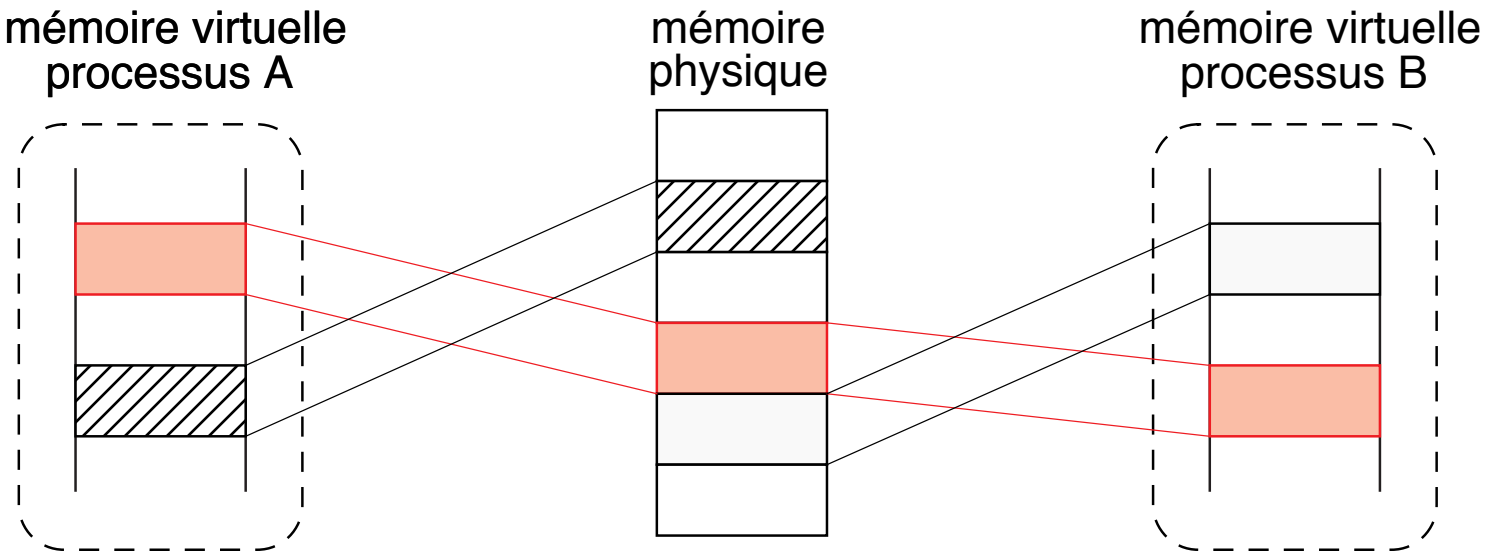

Protection

- contrôle de l'espace d'adressage
  - indicateur spécifique (bit d'« invalidité »)
  - valeur limite associée à la table des pages
- indicateurs pour chaque page, précisant le mode d'accès (lecture, écriture, ajout, exécution...)

Transfert efficace de valeurs : copie sur écriture *(c.o.w.)*

But

Fournir à un processus (B) une copie des données d'un autre processus (A)

Contrainte : les copies doivent être indépendantes (locales à (A) et à (B))

Observation

inutile de dupliquer les données si elles ne sont pas modifiées

→ partager la page des données d'origine en lecture,
et ne dupliquer qu'à la première écriture

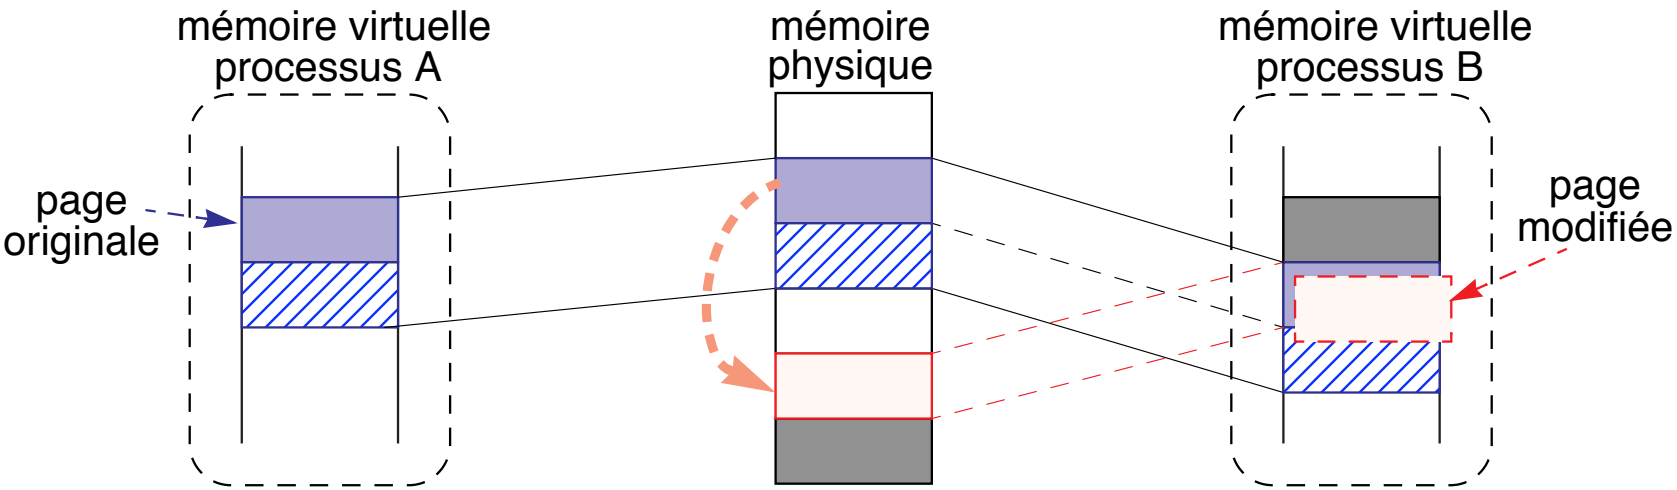

Exemple : mécanisme UNIX de création de processus

duplication sur écriture de l'image mémoire du processus père

Intégration (*couplage*) des fichiers dans l'espace virtuel

Idée : au chargement, les fichiers binaires de code exécutable sont liés (via la table de couplage) à l'image mémoire des processus.
[i.e. les blocs du fichier sont associés à des pages de l'image mémoire]

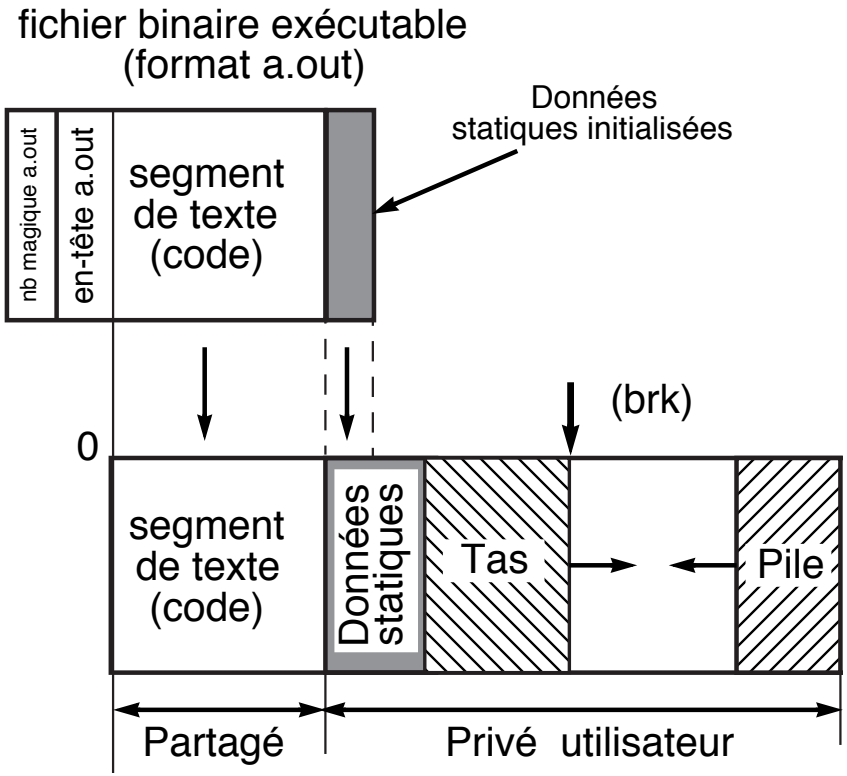

→ utiliser le même mécanisme pour coupler les fichiers de données

- plus d'E/S : contenu du fichier = variables en mémoire
- plus de tampons → moins de recopies → transferts plus efficaces

Intégration (*couplage*) des fichiers dans l'espace virtuel (suite)

Couplage (*mapping*) du fichier en mémoire virtuelle

- fixer 1 adresse de base B en mémoire virtuelle pour le contenu du fichier
- associer le contenu du fichier aux adresses successives à partir de B (coupler les blocs du fichier aux pages successives à partir de B)

Remarques

- couplage $\equiv$ l'ouverture
- accès au fichier $\equiv$ accès à l'image mémoire
- transferts réalisés via le mécanisme de défaut de page
- possibilité de partager un fichier (cf TD)

Systèmes proposant ce mécanisme

Multics (1965) (réalisation systématique des E/S par couplage des fichiers)
Appolo Domain, OS/2, Windows NT, Mach, Linux.

Plan

Hiérarchie de mémoires

Caractéristiques de la pagination avec défaut de page

Deux niveaux de mémoire

- un niveau rapide, mais coûteux et restreint (haut)
- un niveau lent, mais économique et de grande capacité (bas)

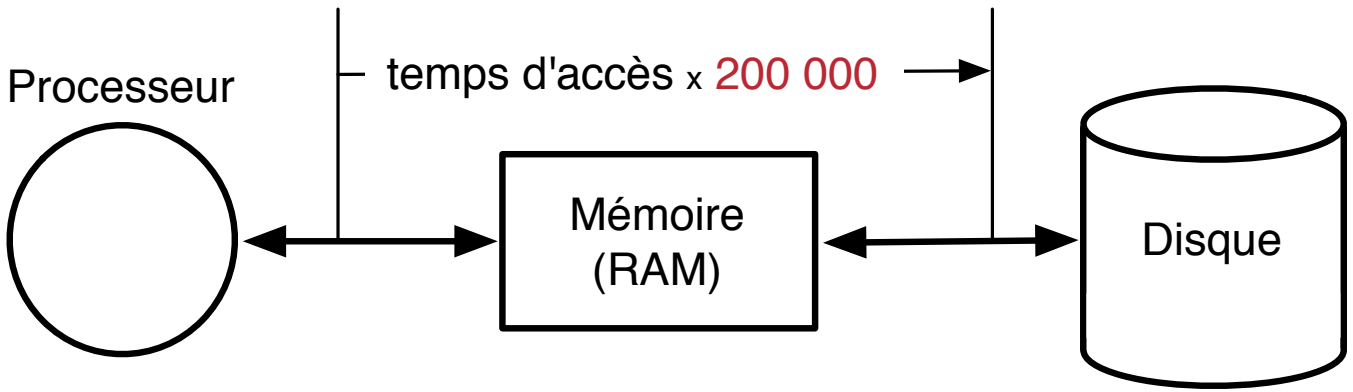

Les données sont

- conservées sur le disque (capacité = 1000 fois celle de la RAM)
- traitées en mémoire centrale (RAM)

Idéal : amener dans le niveau haut les informations dont la fréquence / la probabilité d'utilisation sont les plus grandes

$\rightarrow$ mémoire

- comparable au niveau haut pour les temps d'accès
- comparable au niveau bas pour les capacités

Comment ? *(rappel)*

heuristiques de localité

- spatiale (ensemble de travail) et
- temporelle (LRU)

On dit que le niveau haut (mémoire centrale) joue un rôle d'*antémémoire* (*cache*) pour le niveau bas (mémoire secondaire).

Les idées développées dans le cadre de la pagination sont utilisées pour la hiérarchie des différentes mémoires existantes

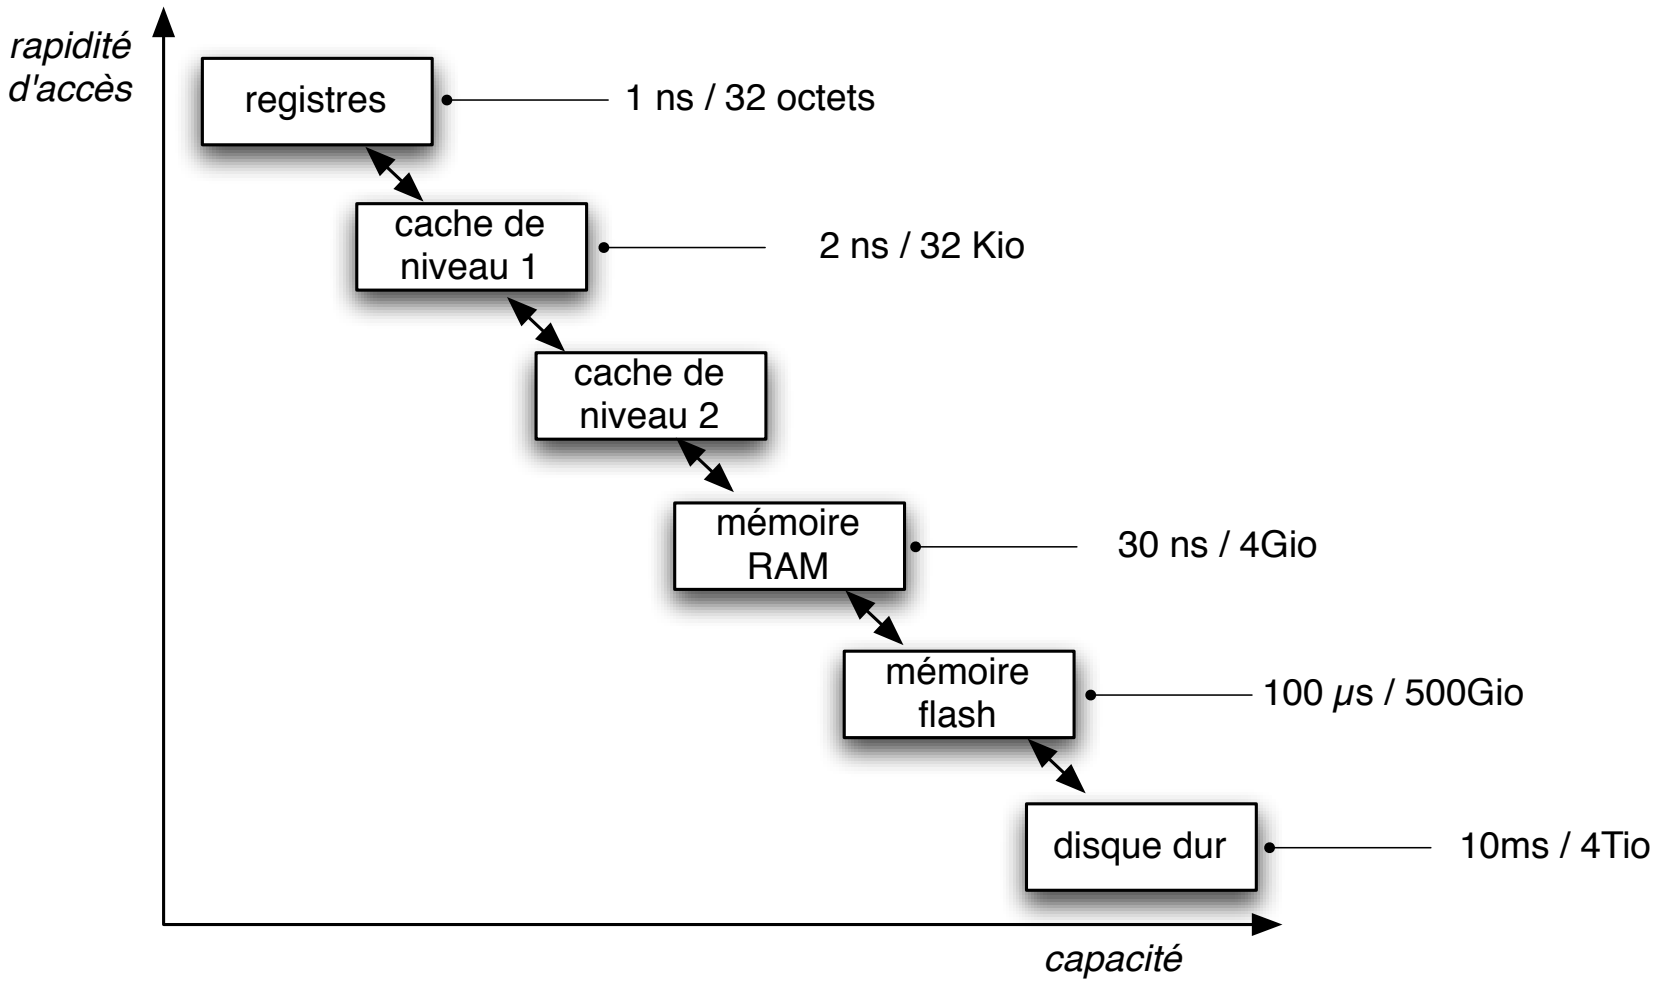

Fonctionnement d'une mémoire cache(niveau matériel)

- une ligne du cache contient, outre les données, un indicateur de validité des données, et une étiquette (*tag*) identifiant l'adresse mémoire centrale à laquelle correspondent les données du cache.
- toutes les informations à lire passent d'abord dans le cache
- écriture dans le cache avec recopie vers la mémoire centrale
- la mémoire cache est découpée en *blocs* (p. ex. 64 octets)
- le cache gère les N dernières références dans une « pile » LRU

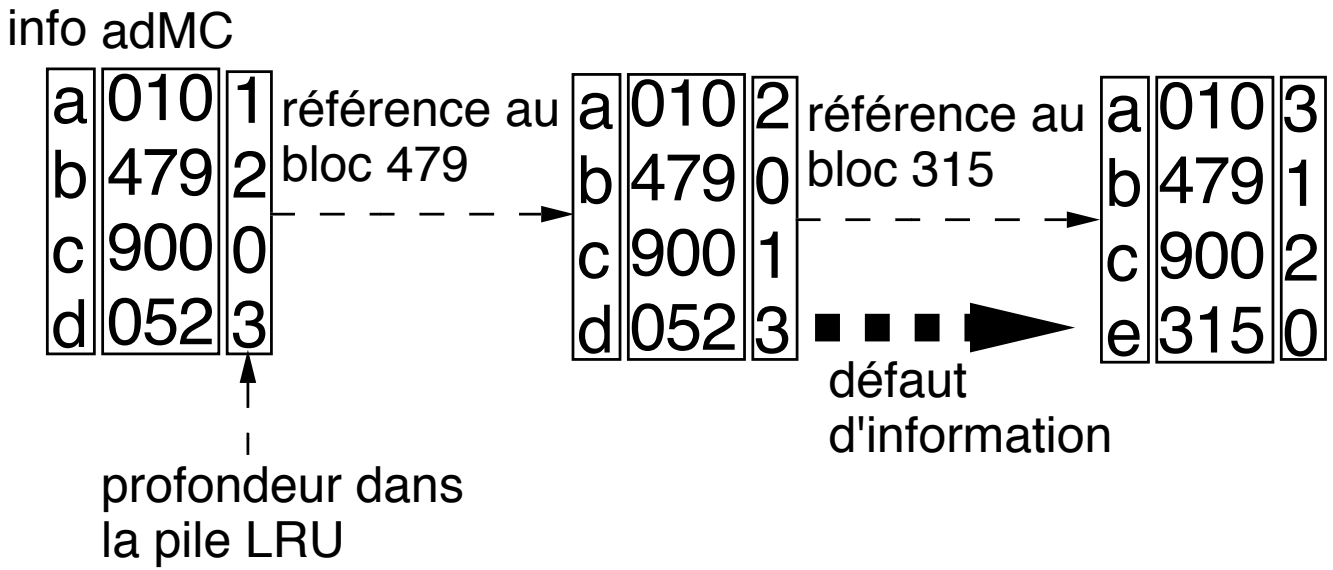

Les colonnes du cache
(cache à correspondace prédéfinie)

Pour réduire le nombre de comparateurs nécessaires,

- La mémoire centrale est divisée en *colonnes* correspondant à une partition de la mémoire, espérée équiprobable.
- Chaque colonne est divisée en *rangées*.
  Une rangée d'une colonne a la taille d'un bloc.
- De même, le cache est divisé en colonnes, puis en rangées.

Chaque colonne du cache joue le rôle de cache pour une colonne de la mémoire.

Les colonnes du cache (suite)

Chaque colonne du cache joue le rôle de cache
pour une colonne de la mémoire.

Analyse d'une adresse

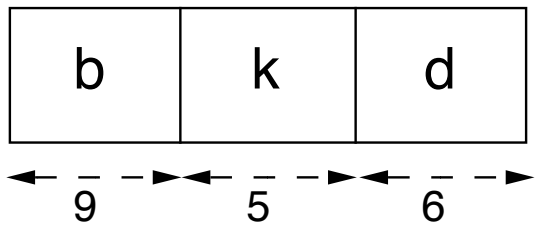

b: numéro de rangée dans la colonne k (ici 512 blocs)
k : numéro de colonne (32 colonnes)
d : déplacement dans le bloc (64 octets)

Exemple : cache de 8 Kio

- 8 Ki / (64*32) = 4 blocs par colonne dans le cache,
- donc 4 comparateurs (au lieu de 128) (128=8 Ki/64)

Si ce cache correspond à une mémoire de 1 Mio,
celle-ci comportera 512 rangées par colonne.

Plan

Etapes de l'implantation d'un programme en mémoire

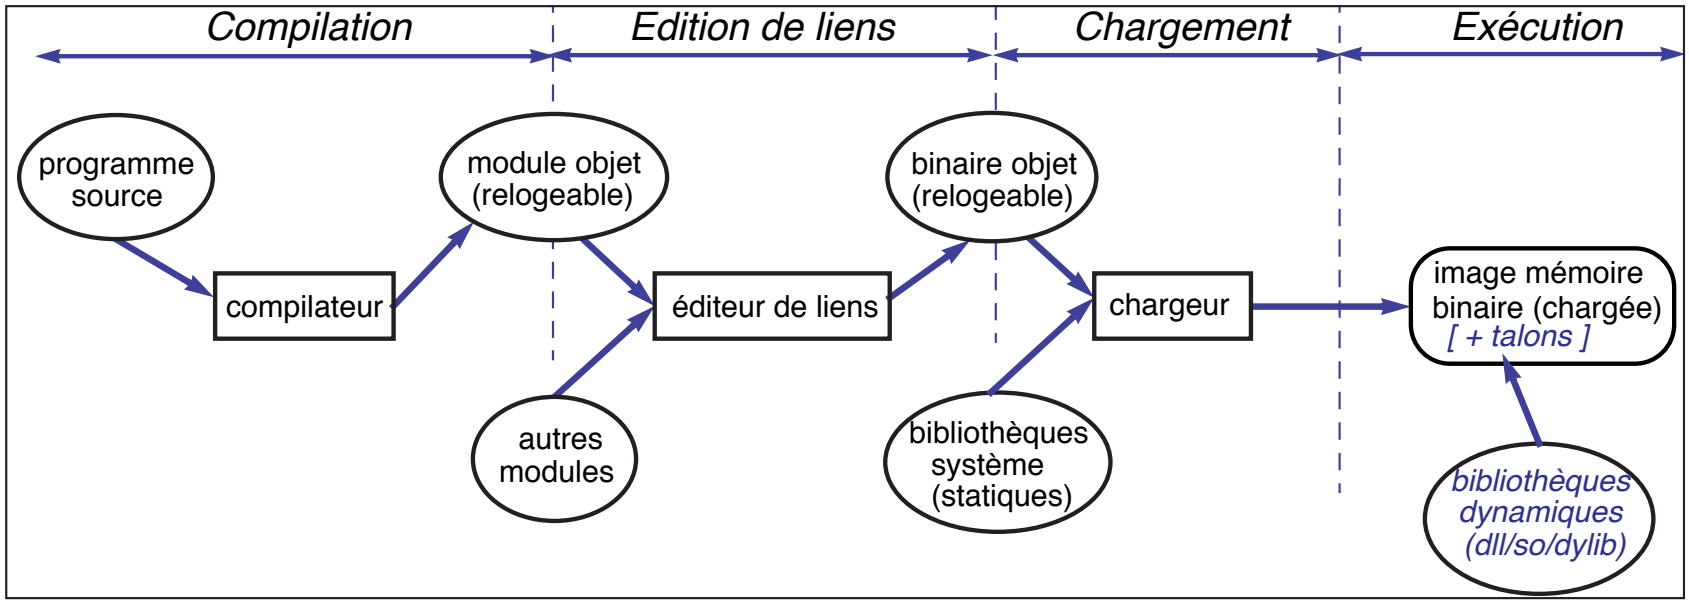

- chargement souvent dynamique → gain de place mémoire : les procédures sont stockées sur disque au format binaire relogeable, et chargées en mémoire à leur premier appel
- L'édition de liens peut être dynamique (bibliothèques)
  - partage et mise à jour automatique du code
  - les procédures à lier dynamiquement sont représentées par un talon qui gère la liaison et se remplace par la procédure effective au premier appel.

Mise en œuvre d'un maillon de la chaîne d'implantation

- *substitution*/inclusion : remplacer chaque occurence de l'objet abstrait (symbole) par sa correspondance concrète (adresse)

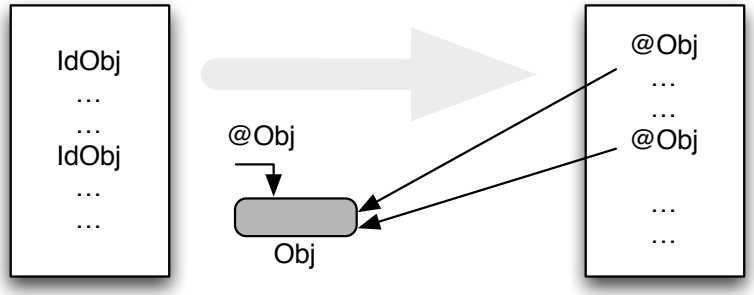

  - simple, statique, efficace
  - une *table de traduction*, indiquant la position des occurrences de chacun des objets substitués dans le code d'origine doit être conservée, si l'on veut pouvoir refaire l'étape
- *chaînage*/indirection : remplacer chaque occurence de l'objet abstrait par l'adresse d'une référence vers l'objet concret.
  - plus souple, mais moins efficace

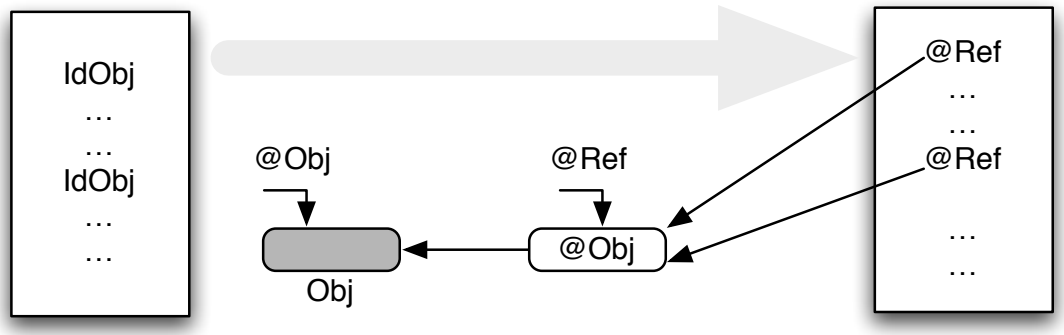

Format du binaire relogeable [1]

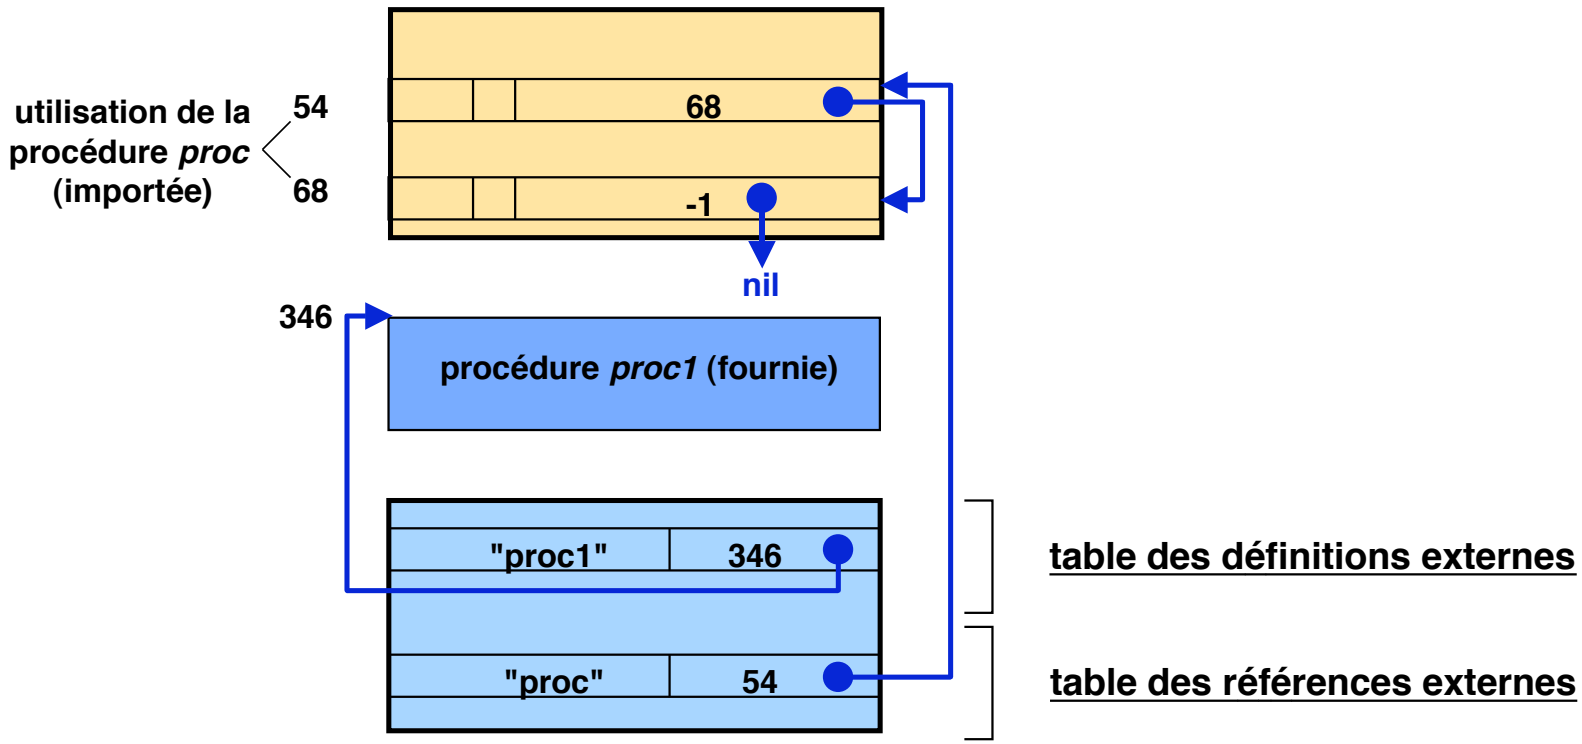

1. Source : S. Krakowiak

Edition de liens [2]

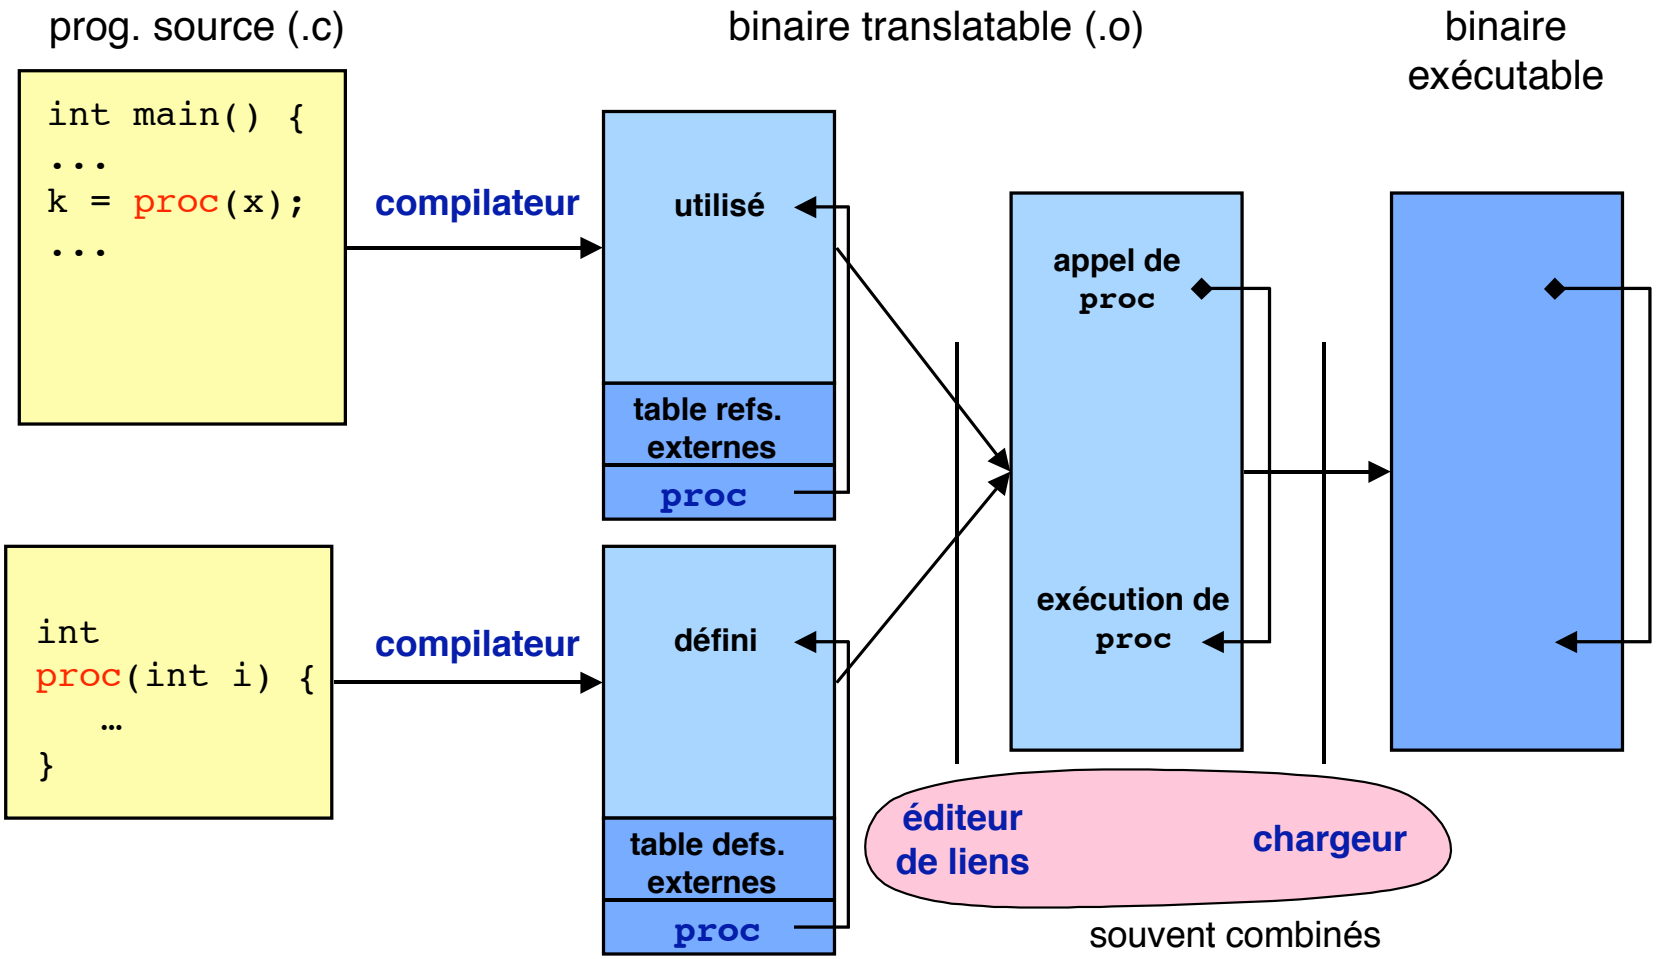

2. Source : S. Krakowiak

Chaîne d'implantation d'un programme en mémoire : résumé

avec gcc [3]

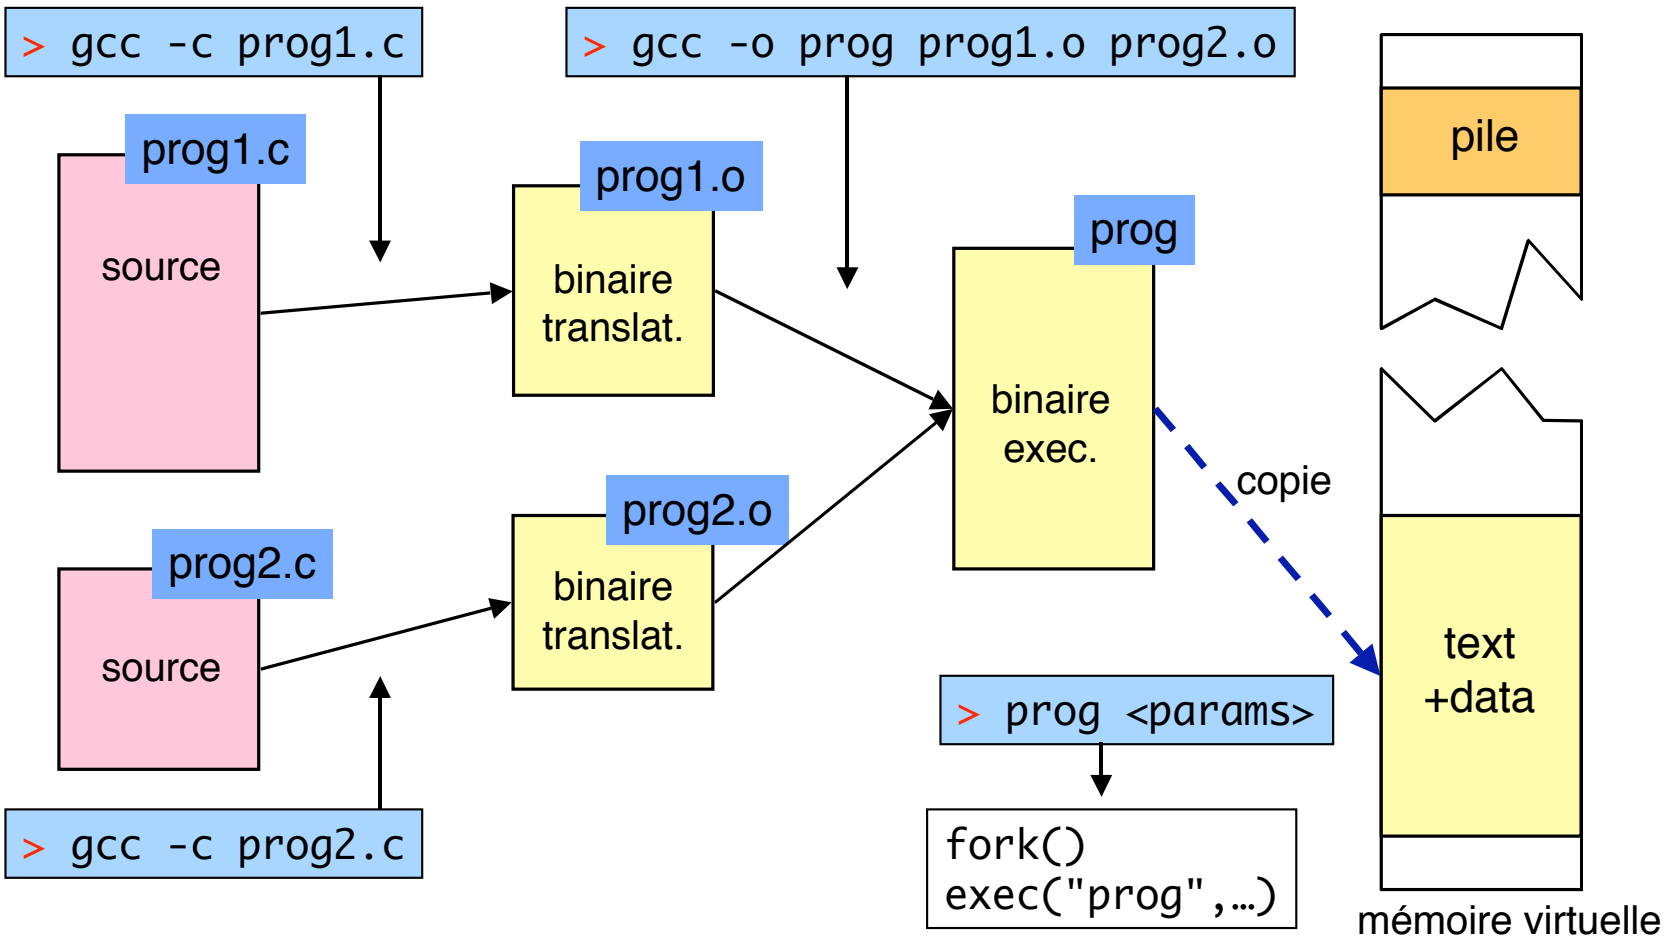

3. Source : S. Krakowiak

Exemple : image mémoire d'un processus Unix

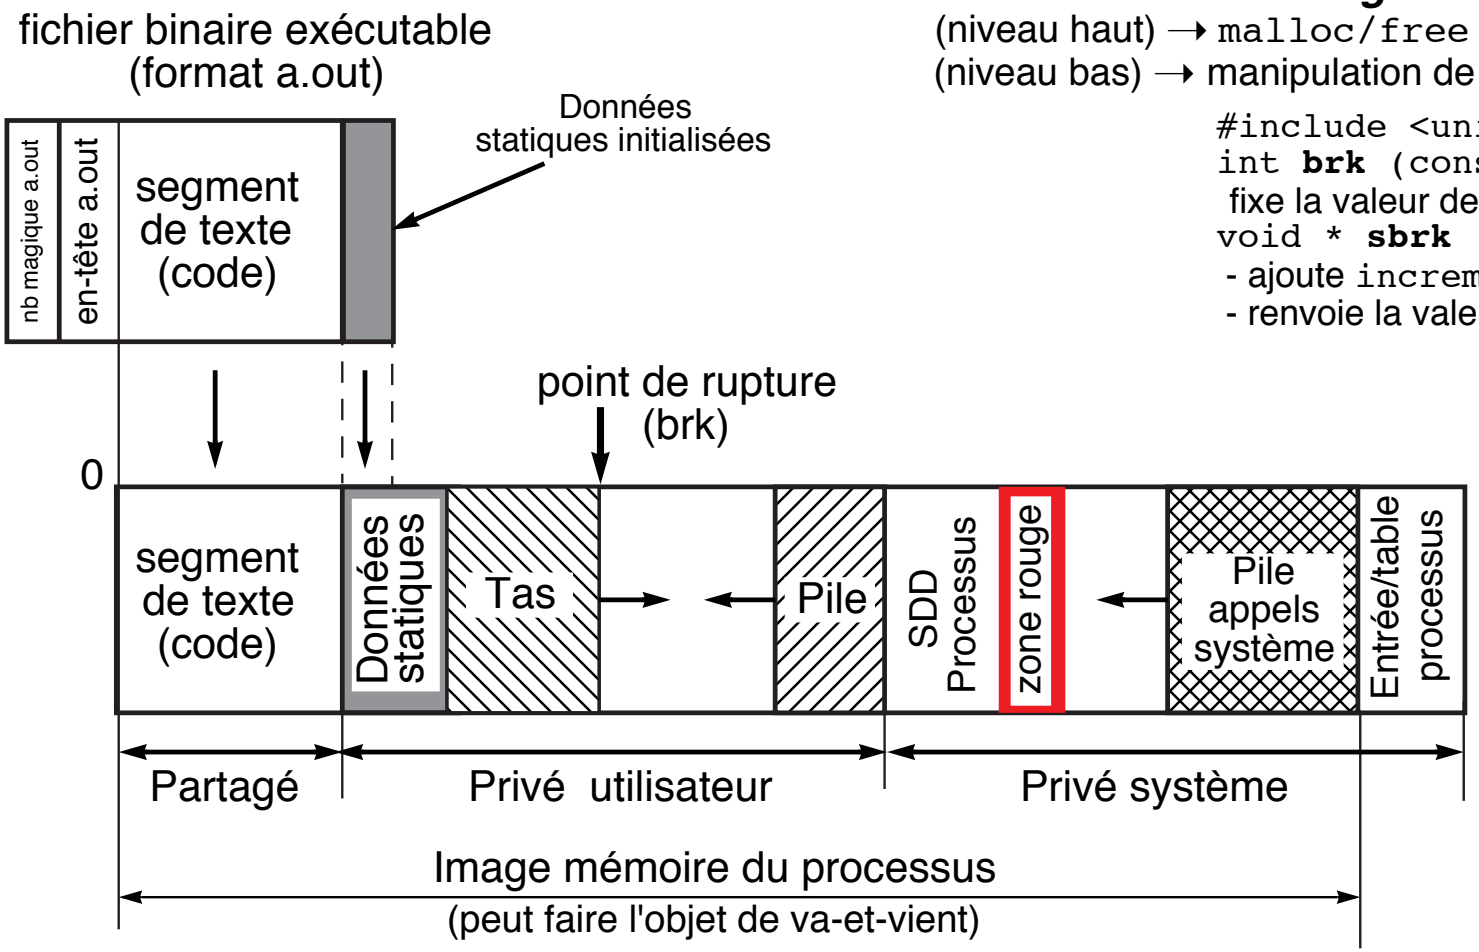

Interface du service de gestion mémoire :

(niveau haut) → `malloc/free (stdlib.h)`

(niveau bas) → manipulation de `brk` :

```
#include <unistd.h>
int brk (const void *ptr)
 fixe la valeur de brk
void * sbrk (int increment)
 - ajoute increment
 - renvoie la valeur précédente de brk
```

Plan

Gestion mémoire sous UNIX 4.x BSD

Va et vient

- le va et vient est appliqué, mais dans des cas peu fréquents (prévention de l'écroulement, processus inactifs) : les processus sont suspendus par le processus scheduler
  - lorsque la charge est élevée
  - et que la mémoire libre est en dessous d'un seuil minimum (lotsfree $\approx$ 1/64mémoire totale), durant trop longtemps
- le scheduler suspend alors (et répète jusqu'à avoir plus de lotsfree mémoire libre)
  - le processus inactif depuis le plus longtemps, parmi ceux inactifs depuis plus de 20s
  - le plus gros processus inactif depuis le plus longtemps
- la gestion « courante » de la mémoire est basée sur la pagination

Gestion mémoire sous UNIX 4.x BSD (suite)

Pagination

- Pagination à 2 niveaux
- taille des pages indépendante du matériel ($\geq$ 512 octets)
- pages verrouillables (non éjectables) (attente E/S, va-et-vient)
- les pages d'un processus sont généralement préchargées
  (et mises dans la liste des pages libres, étant marquées récupérables)
- une *table des cases* est gérée (liste inverse)
- et parcourue circulairement, s'il faut libérer de la place (proc. *pagedaemon*)
  - les cases déjà libres ou verrouillées ne sont pas touchées
  - sinon, si le processus auquel la case est allouée a suffisamment d'espace mémoire
    - la page est éventuellement sauvée sur disque (bit « modifié »)
    - la case est marquée comme libre mais récupérable
    - la page correspondante est marquée comme invalide
- pagedaemon est réveillé
  - lorsque le processus scheduler en a besoin
  - quand le nombre de cases libres est au dessous d'un seuil (lotsfree) (1/64 mémoire totale)
- pagedaemon utilise moins de 10% du temps processeur.

Solaris

Gestion de la mémoire virtuelle : segmentation paginée

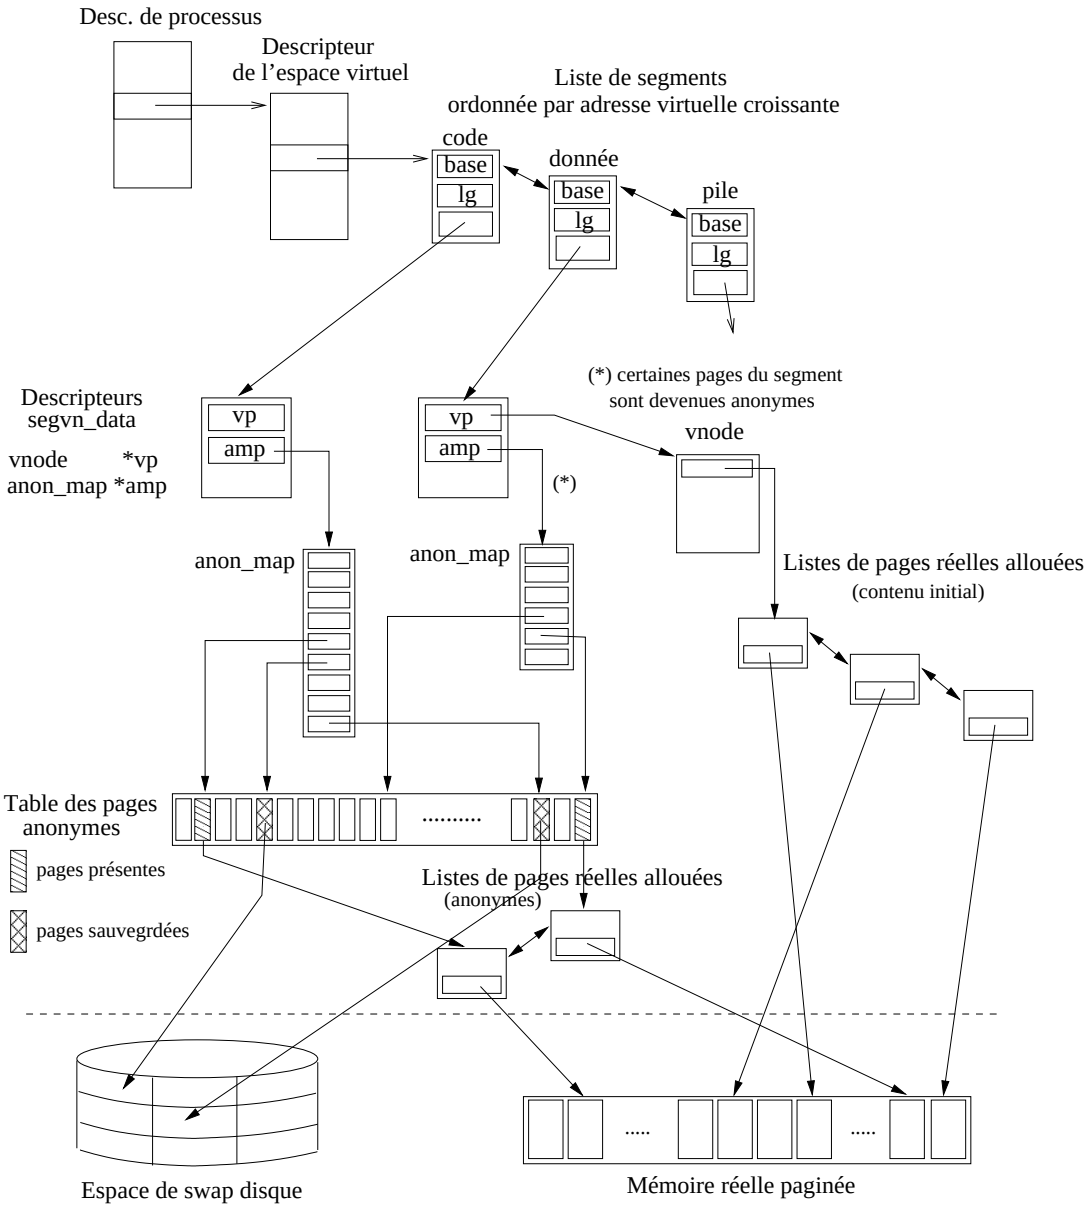

Solaris (suite)

Gestion de la mémoire noyau : allocation de plages (slabs)

Principe

- une *plage* (slab) est une suite de cases contiguës
- un *cache* est composé d'une ou plusieurs plages
- chaque structure de données (SdD) du noyau (descripteurs de processus, de fichiers. . .) est associée à un cache, qui contiendra les instances (objets) de cette SdD
- lorsqu'un cache est créé, il est peuplé d'un nombre déterminé d'objets marqués comme *libres*
- les objets d'un cache sont alloués et marqués *utilisés* au fur et à mesure des besoins

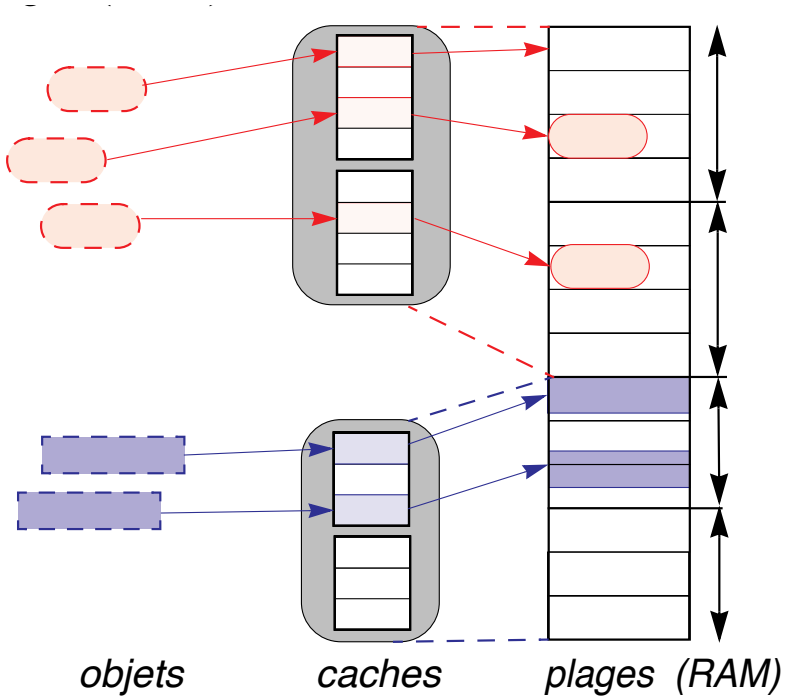

- une demande d'allocation est servie en cherchant d'abord une plage partiellement remplie, puis une plage vide
- si toutes les plages sont pleines, une nouvelle plage est créée et associée au cache

Avantages

- pas de fragmentation : ensemble de tailles prédéterminé (structures du noyau), extension dynamique des plages, allocation aux plages par pages de taille unique
- efficacité : allocation (objets libres pré-créés) et libération (indicateur libre)

Windows NT

Structure

- Mémoire à deux niveaux : segmentation et pagination
- Adresses virtuelles sur 32 bits ⇒ 4G octets adressables
- Découpage logique :
  - Intelx86 : 1024 segments de 1024 pages de 4K
  - Digital Alpha : 256 segments de 2048 pages de 8K

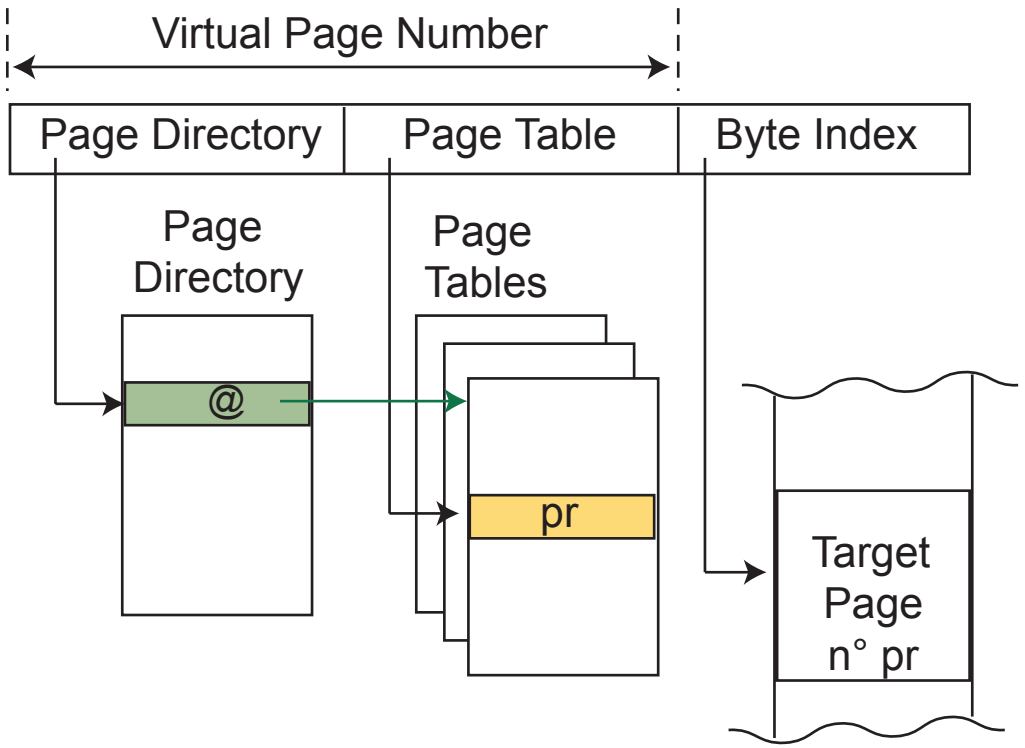

Page directory = table des segments, implantée à une adresse fixe

Règles de couplage

- Une zone interdite : 0x0 à 0xFFFF
  (64Ko de début, référencée par les pointeurs "nuls")
- Zone programme applicatif : 0x10000 à 0x7FFEFFFF (2G - 128K)
- Une zone interdite : 0x7FFF0000 à 0x7FFFFFFF (64Ko)
- Zone noyau : 0x80000000 à 0xFFFFFFFF (2G)

Programmation du couplage en 2 étapes

- réservation/libération d'un espace d'adressage (région) ;
- couplage/découplage proprement dit d'un contenu.

Primitives

- *VirtualAlloc/VirtualFree* : réservation/libération
  (et (dé)couplage de pages)
- *VirtualLock/VirtualUnlock* : (dé)verrouillage en mémoire
- *CreateFileMapping/MapViewOfFile/UnmapViewOfFile* :
  définition/couplage/découplage de fichiers

Couplage de fichiers sous Windows NT : primitives

Réservation/libération d'une région et (dé)couplage de pages

```
LPVOID VirtualAlloc (
    LPVOID lpAddress, // adresse de base
    DWORD dwSize, // taille en octets
    DWORD flAllocationType, // type d'opération
    DWORD flProtect, // attributs de protection
);
LPVOID VirtualFree (
    LPVOID lpAddress, // adresse de base
    DWORD dwSize, // taille en octets
    DWORD dwFreeType, // type d'opération
);
```

avec :

```
flAllocationType = {MEM_RESERVE, MEM_COMMIT, MEM_RESET}
dwFreeType={MEM_RELEASE, MEM_DECOMMIT}
```

Couplage de fichiers sous Windows NT : primitives

Couplage de contenu

Etapes

1. Créer ou ouvrir le fichier : *CreateFile, OpenFile* ;
2. Définir le couplage du fichier : *CreateFileMapping* ;
3. Associer une région au fichier : *MapViewOfFile*.

```
HANDLE CreateFileMapping (
    HANDLE hFile, // le fichier
    LPSECURITY_ATTRIBUTE lpFileMappingAttributes,
    DWORD flProtect, // attributs de protection
    DWORD dwMaximumSizeHigh, // forts poids
    DWORD dwMaximumSizeLow, // faibles poids
    LPCTSTR lpName
);
```

avec :

`flProtect = {PAGE_READONLY,PAGE_READWRITE,PAGE_WRITECOPY}`

☞ `PAGE_WRITECOPY` : voir `FILE_MAP_COPY`

Couplage de fichiers sous Windows NT : primitives

Réserver/Libérer une région en mémoire virtuelle

```
LPVOID MapViewOfFile (
   HANDLE hFileMappingObject, // l'objet couplage
   DWORD dwDesiredAccess,
   DWORD dwFileOffsetHigh, // forts poids
   DWORD dwFileOffsetLow, // faibles poids
   DWORD dwNumberOfBytesToMap
);
BOOL UnmapViewOfFile(
   LPCVOID lpBaseAddress
);
```

avec :

```
dwDesiredAccess =
    {FILE_MAP_WRITE,FILE_MAP_READ,FILE_MAP_COPY}
```

☞ `FILE_MAP_COPY` : fichier original non modifié